REPUBLIQUE DU CAMEROUN
PAIX - TRAVAIL – PATRIE
****
UNIVERSITE DE DSCHANG
****
ÉCOLE DOCTORALE

REPUBLIC OF CAMEROON
PEACE - WORK - FATHERLAND
****
UNIVERSITY OF DSCHANG
****
POST GRADUATE SCHOOL

DSCHANG SCHOOL OF SCIENCES AND TECHNOLOGY

UNITE DE RECHERCHE EN INFORMATIQUE FONDAMENTALE, INGENIERIE ET APPLICATIONS (URIFIA)

SUJET :

UTILISATION D'UN DATA MINING WORKFLOW ET DU MACHINE LEARNING POUR LA PREDICTION DES GENES ESSENTIELS CHEZ CERTAINS ORGANISMES VIVANTS : CAS DES SRB

Mémoire soutenu publiquement en vue de l'obtention du
diplôme de Master en Informatique

Option : Informatique Fondamentale
Spécialité : Intelligence Artificielle

Par

FOFACK JUNIOR BASILE
*Matricule : **CM-UDS-18SCI2103***
Licence en Informatique Fondamentale

Sous la direction de :

Dr BOMGNI ALAIN BERTRAND
Chargé de cours, Université de Dschang, Cameroun

Année académique 2022/2023

DÉDICACE

À mes parents.

REMERCIEMENTS

Je tiens à remercier toutes les personnes qui ont contribué de prêt ou de loin au succès de ce travail. Je voudrais tout d'abord adresser toute ma gratitude à mon encadreur **Dr BOMGNI Alain Bertrand** pour sa patience, sa disponibilité et surtout ses judicieux conseils, qui ont contribué à alimenter ma réflexion.

En témoignage de ma gratitude et de mon profond respect, j'adresse mes vifs et sincères remerciements :

— À tous les membres du jury, pour l'honneur qu'ils m'accordent en appréciant ce travail ;
— À tous les enseignants du département de Mathématiques-informatiques qui m'ont fourni les outils nécessaires à la réussite de mes études universitaires ;
— Au Dr LONLAC Jerry, pour ses critiques, ses remarques, ses multiples conseils et ses encouragements ;
— À mes parents, DONKEU Gilbert et KATEU Victorine, pour leurs conseils ainsi que leur soutien inconditionnel, à la fois moral et financier, qui m'ont permis de réaliser les études de choix par conséquent ce mémoire ;
— À TSOFACK Valentin et DJIFACK Cécile pour les efforts que vous avez consentis pour assurer mon parcours académique ;
— À Mme Bomgni pour le soutient multiforme et ses encouragements ;
— À Fotie warren pour son soutien inconditionnel et ses encouragements ;
— À LETENOU marie pour son aide et ces encouragements ;
— À tous les membres de ma famille qui ont cru en moi et m'ont soutenu tant moralement que physiquement pour l'atteinte de cet objectif ;
— À tous mes camarades de promotion de Master 2 Recherche pour les discussions que nous avons partagées ;
— À tous mes aînés académiques qui m'ont toujours soutenu, conseillé et qui m'ont donné le courage d'avancer dans les recherches ;
— À toutes les personnes qui ont participé de près ou de loin à mes travaux de recherche et à l'élaboration de ce mémoire. Je vous serai éternellement reconnaissant.

TABLE DES MATIÈRES

Dédicace i
Remerciements ii
Table des matières iii
Liste des Acronymes vi
Liste des tableaux vii
Table des figures viii
Résumé x
Abstract xii

Introduction générale **1**
contexte du travail 1
Problématique étudiée et objectifs 2
Contribution 3
Organisation du manuscrit 4

Chapitre I ► **Généralités sur l'intelligence artificielle et Data mining workflow** **5**
I.1 - Introduction 5
I.2 - Types d'intelligence artificielle 6
I.2.1 - Intelligence artificielle faible 6
I.2.2 - Intelligence artificielle forte ou l'IA généralisée 7
I.3 - Le machine Learning 7
I.3.1 - Apprentissage supervisé 8
I.3.2 - Apprentissage non supervisé 10
I.3.3 - Apprentissage semi-supervisé 11
I.3.4 - Apprentissage par renforcement 11
I.4 - Deep Learning 12
I.4.1 - Réseaux de neurones artificiels 13
I.4.2 - Les réseaux de neurones récurrents 13
I.4.3 - Les réseaux LSTM(Long Short-Term Memory) 14
I.4.4 - Réseaux de neurones convolutifs 16

I.5 - Data mining workflow 18
I.5.1 - Fonctionnement du data mining 18
I.5.2 - Techniques du data mining 20
I.5.3 - Importance du data mining 21
I.5.4 - Quelques domaines d'application du data mining 22
I.6 - Conclusion 23

Chapitre II ► **État de l'art sur la prédiction des gènes essentiels** **24**
II.1 - Introduction 24
II.2 - Vocabulaire de quelques termes de la biologie 25
II.3 - Présentation du matériel génétique 26
II.3.1 - Cellule 26
II.3.2 - Chromosomes 27
II.3.3 - Acide désoxyribonucléique (ADN) 27
II.3.4 - Gènes 28
II.3.5 - Importances des gènes essentiels 29
II.4 - Approches de prédiction des gènes essentiels 30
II.4.1 - Approches basées sur l'apprentissage automatique supervisé . 30
II.4.1.1 - Approches utilisant les machines à vecteurs de support (SVM) 30
II.4.1.2 - Approches utilisant le classificateur XGBoost 31
II.4.1.3 - Approches utilisant le classificateur Random Forest et le Gradient Boosting Method 32
II.4.2 - Approche basé sur la méthode d'apprentissage automatique semi-supervisé 34
II.4.3 - Approche basée sur l'apprentissage en profondeur 35
II.4.3.1 - Approche utilisant les réseaux de neurones à plusieurs couches 35
II.4.3.2 - Approche utilisant les réseaux de neurones à rétro-propagation (BPNN) 37
II.5 - Conclusion 39

Chapitre III ► **Contribution à la prédiction des gènes essentiels** **40**
III.1 - Introduction 40
III.2 - Description de l'approche proposée 41
III.3 - Workflow d'exécution de la méthode proposée 41
III.3.1 - Collecte des données sur les organismes SRB (Data SRB collection) 42

III.3.2 - Data preprocessing 43
III.3.3 - Training process 48
III.4 - Résultat de simulation et discussion 54
III.4.1 - Présentation de l'environnement de travail 54
III.4.2 - Résultats des simulations 54
III.4.3 - Discussion 63
III.5 - Conclusion 64

Conclusion générale **65**
La problématique étudiée et les choix méthodologiques 65
Analyse critique des résultats obtenus 66
Quelques perspectives 66

Bibliographie **68**

LISTE DES ACRONYMES

ADN	Acide DésoxyriboNucléique
ARN	Acide RiboNucléique
AUC	Area Under the Curve
BPNN	backpropagation neural network
CNN	Convolutional Neural Networks
DL	Deep Learning
EGPS	Essential Gene Prediction System
FBA	Flux Balance Analysis
GLM	Generalised Linear Model
GBM	Gradient Boosting Method
IA	Intelligence Artificielle
IT	information-theoretic
LSTM	Long Short-Term Memory
ML	Machine Learning
MLP	Multi Layer Perceptrons
MRMR	Maximum Relevance Minimum Redundancy
NN	Neuronal Network
LGC	Local and Global Consistency
PPI	protein-protein interaction
PR-AUC	Area under the precision-recall curve
ROC	Receiver Operating Characteristic
ROC-AUC	Area under the receiver operating characteristic curve
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Support Vector Machine

LISTE DES TABLEAUX

I - Regroupement des 50 organismes utilisés dans ce travail en famille . . . 48
II - Nombre de gène essentiel et non essentiels des 40 organismes d'entraînement 50

TABLE DES FIGURES

1 - Intelligence artificielle vs Machine Learning vs Deep Learning :[14] . . 6
2 - Intelligence artificielle faible vs intelligence artificielle forte[15] 7
3 - Apprentissage supervisé 8
4 - Régression vs Classification[18] 9
5 - Apprentissage non supervisé 10
6 - Apprentissage par renforcement [21] 12
7 - Réseaux de neurones artificiels [22] 13
8 - Exemple de réseau de neurone récurrent [24] 14
9 - Architecture des Long Short-Term Memory [26] 16
10 - Architecture d'un réseau de neurone convolutif [31] 17
11 - Fonctionnement du data mining [32] 19

12 - Éléments du matériel génétique[33] 26
13 - LA STRUCTURE DE LA MOLÉCULE D'ADN [38] 28
14 - Architecture du modèle proposé par Olufemi A. et Thomas B. [36] . . 31
15 - Workflow du modèle de[36] 33
16 - Architecture du modèle proposé par Xiao L. et Yachuan L. [39] 34
17 - Architecture du modèle DeepHE [40] 36
18 - Architecture du modèle proposé par Xiao Liu, Yachuan L. et Ting He [41] 38

19 - Architecture de l'approche proposée 41
20 - Workflow d'exécution de l'approche proposée 42
21 - Fichiers fasta construit des séquences des nucléotides et des séquences de protéines. 44
22 - propositions des classes avant et après rééchantillonage 51
23 - Matrice de confusion 52
24 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme afg 55
25 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme bcg 56

26 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme bcu 57
27 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme bcz 58
28 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme cbh 59
29 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme csr 60
30 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme ckr 61
31 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme dsa 62
32 - Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme dor 63

RÉSUMÉ

Le génome des organismes vivants est constitué d'un ensemble de gènes dont certains sont essentiels au sein dudit organisme. Les gènes essentiels sont d'une importance cruciale pour la survie et la reproduction des organismes vivants. L'identification rapide de ces gènes essentiels est d'une aide salvatrice dans les domaines de la biomédecine et de la biotechnologie. Pour leur identifier, de nombreuses méthodes d'apprentissage automatique ont été largement utilisées pour prédire les gènes essentiels des organismes et ont obtenu des résultats satisfaisants. Cependant, la plupart des classificateurs proposés dans ces méthodes présentent de meilleures performances en termes de prédiction intra-organismes et laissent une marge d'erreur considérable en termes de prédiction inter-organisme ou extra-organisme. Dans ce mémoire, nous proposons une nouvelle approche de prédiction des gènes essentiels basée sur l'apprentissage automatique nommé SystPredGE. Dans cette approche, nous montrons que les performances des classificateurs peuvent être améliorées sur des caractéristiques minimales pertinentes en prenant en compte la taxonomie des différents organismes. Un total de 28835 caractéristiques a été générées à partir des séquences de nucléotides et de protéines de 50 organismes SRB (Sulfate Reducing Bacteria) pour construire un système de modèles d'apprentissage automatique dans le but de prédire les gènes essentiels. En utilisant la validation croisée, nous avons obtenu une excellente performance de prédiction. Les meilleurs modèles obtenus sur les 40 organismes d'entraînement ont un AUC de 0,97, une pression de 0,99, un recall de 0,99 et un score F1 de 0,99. Ce système a été utilisé ensuite pour prédire les gènes de 10 organismes SRB (Archaeoglobus fulgidus DSM 8774(afg), Bacillus cereus G9842(bcg), Bacillus cereus AH820(bcu), Bacillus cereus E33L(bcz), Clostridium kluyveri NBRC 12016(ckr), Clostridium saccharoperbutylacetonicum(csr), Clostridium botulinum A Hall(cbh), Desulfovibrio salexigens(dsa), Desulfosporosinus orientis(dor)). Les résultats obtenus sur ces organismes de test ont montré l'efficacité de SystPredGE avec une précision maximale, un recall maximal, un f1-score maximal et un Auc maximal respectivement égale à 0,99, 0,99, 0,99, 0,98. Notre approche a considérablement surpassé les approches proposées jusqu'à présent. Ces résultats montrent une meilleure généralisation des modèles proposés.

Mots clés : Gènes essentiels, caractéristiques, prédiction intra-organisme, prédiction inter-organisme, machine learning, SRB.

USE OF A DATA MINING WORKFLOW AND MACHINE LEARNING FOR THE PREDICTION OF ESSENTIAL GENES IN CERTAIN LIVING ORGANISMS : CASE OF SRB

ABSTRACT

The genome of living organisms is made up of a set of genes, some of which are essential within said organism. Essential genes are of crucial importance for the survival and reproduction of living organisms. The rapid identification of these essential genes is a life-saving aid in the fields of biomedicine and biotechnology. To identify them, many machine learning methods have been widely used to predict the essential genes of organisms and have achieved satisfactory results. However, most of the classifiers proposed in these methods have better performance in terms of intra-organism prediction and leave a margin of error for consideration in terms of inter-organism or extra-organism prediction. In this thesis, we propose a new machine learning-based essential gene prediction approach named SystPredGE. In this approach, we show that the performance of classifiers can be improved on minimal relevant features by taking into account the taxonomy of different organisms. A total of 28835 features were generated from the nucleotide and protein sequences of 50 SRB (Sulfate Reducing Bacteria) organisms to build a system of machine learning models to predict essential genes. By using cross-validation, we obtained an excellent prediction performance. The best models obtained on the 40 training organizations have an AUC of 0.97, a pressure of 0.99, a recall of 0.99 and an F1 score of 0.99. This system was then used to predict the genes of 10 SRB organisms (Archaeoglobus fulgidus DSM 8774(afg), Bacillus cereus G9842(bcg), Bacillus cereus AH820(bcu), Bacillus cereus E33L(bcz), Clostridium kluyveri NBRC 12016(ckr), Clostridium saccharoperbutylacetonicum(csr), Clostridium botulinum A Hall(cbh), Desulfovibrio salexigens(dsa), Desulfosporosinus orientis(dor)). The results obtained on these test organisms showed the effectiveness of SystPredGE with maximum precision, maximum recall, maximum f1-score and maximum Auc respectively equal to 0.99, 0.99, 0.99, 0, 98. Our approach has significantly outperformed the approaches proposed so far. These results show a better generalization of the proposed models.

Keywords : Essential genes, characteristics, intra-organism prediction, inter-organism prediction, machine learning, SRB.

INTRODUCTION GÉNÉRALE

CONTENTS

contexte du travail 1
Problématique étudiée et objectifs 2
Contribution 3
Organisation du manuscrit 4

contexte du travail

La génétique est la science principale pour aborder pratiquement toutes les grandes préoccupations biologiques. Elle aide à comprendre le processus d'expression continue de protéines, codées par des gènes présents dans le génome. La classification *COG* (Clusters of Orthologous Genes) [1] a regroupé les gènes en différentes catégories en se basant sur leurs fonctions au sein de l'organisme, les voies métaboliques auxquelles ils sont associés. Les gènes chargés de faire fonctionner le système cellulaire et de le maintenir en vie sont contenus dans la catégorie de gènes domestiques [2, 3]. Parmi ces gènes, certains sont vitaux pour la survie ou le développement des organismes tout en leur permettant de vivre dans certaines conditions environnementales telles que aérobie et anaérobie. Ces gènes sont dits **gènes essentiels**. Lorsqu'un gène essentiel est abîmé ou détérioré ou manquant, cela peut conduire à des répercussions dangereuses, telles que des défauts de développement, des maladies génétiques ou même la mort de l'organisme. C'est dans cette optique que l'identification de ces gènes est cruciale pour comprendre les mécanismes sous-jacents des processus biologiques fondamentaux (division cellulaire, synthèse protéique, métabolisme énergétique), des processus cellulaires, et identifier de nouvelles cibles thérapeutiques pour le traitement de maladies infectieuses ou génétiques. Le décryptage génomique des organismes vivants connaît un essor important depuis les années 1980 [4] donnant d'énormes quantités de gènes

pour chaque organisme vivant. La détermination de ceux qui sont essentiels parmi ses gènes nécessite une analyse systématique à l'aide d'outils expérimentaux, désormais complétés par des outils informatiques. Ces outils informatiques sont des algorithmes d'intelligence artificielle, une méthode prometteuse pour prédire les gènes essentiels à l'aide de données génomiques. Cette technique peut analyser de grandes quantités de données et découvrir des modèles complexes qui peuvent être utilisés pour prédire si un gène est essentiel pour un organisme particulier.

Problématique étudiée et objectifs

La connaissance du statut d'essentialité d'un gène pour un organisme favorise la compréhension des fonctions biologiques de ce gène et son rôle dans la survie et la croissance des cellules de son détenteur. Les méthodes d'identification de ces gènes essentiels sont principalement des méthodes expérimentales et des méthodes informatiques. Parmi ces techniques expérimentales couramment utilisées qui peuvent fournir des résultats assez précis, nous avons l'inactivation de gène [5], la mutagenèse par transposons [6] et l'interface ARN [7]. Ces approches expérimentales sont des méthodes fiables pour identifier les gènes essentiels en raison des études expérimentales approfondies sur des organismes modèles comme Escherichia coli et Saccharomyces cerevisiae [8]. Cependant, ces méthodes sont complexes, coûteuses, chronophages et laborieuses [9]. Au regard de ces inconvénients et de la complexité de ces approches in vitro, plusieurs méthodes de calcul ont été développées pour prédire l'essentialité des gènes, parmi lesquelles l'approche ayant gagné en popularité ces dernières années est l'approche informatique basée sur l'intelligence artificielle [10], tels que les algorithmes d'apprentissage automatique ont été utilisés pour prédire les gènes et les protéines essentiels, tels que la machine à vecteurs de support (SVM), les arbres de décision, le bayésien naïf, le réseau de neurones (NN). Ces méthodes informatiques ou computationnelles ont été développées pour compléter les techniques expérimentales afin de minimiser les ressources nécessaires aux tests d'essentialité d'un gène donné. Bien que, ces approches informatiques prédisent de manière fiable les gènes intra-organismes, elles ne sont pas encore déterministes pour la prédiction des gènes inter-organismes ou extra-organismes. En se focalisant sur la validation inter-organismes, certains chercheur tels que (Qian Zhou, Saibing Qi, et Cong Ren) [11], ont récemment proposé de nouvelles approches de prédiction des gènes inter-organismes basé sur des réseaux de neurones à pointes convolutifs (SNN) avec une règle d'apprentissage de la plasticité dépendante du temps de pointe modulée par la récompense pour apprendre à

partir des images de représentation du jeu de chaos de la matrice de fréquence des gènes essentiels et non essentiels. Les marges d'erreurs laissées par leurs classificateur ne sont pas négligeable(en moyenne de 4%).

Dans ce travail, nous allons nous pencher sur l'amélioration des performances de prédiction ainsi que la généralisation du modèle pour une adaptation sur plusieurs organismes ayant des données distinctes. Pour y arriver, nous nous fixons plusieurs objectifs notamment :

— définir pour chaque sous-groupes de caractéristique, un nouveau modèle de prédiction des gènes essentiels inter-organismes basé sur la corrélation des gènes des organismes considérés ;
— paramétrer les modèles misent sur pied pour obtenir de meilleure performance supérieure à celles présentées dans la littérature ;
— généraliser le modèle pour qu'il soit capable de prédire le statut d'éssentialité des gènes des autres organismes SRB ayant jamais connu auparavant.

Contribution

Pour apporter les éléments de solution à notre problématique qui est la prédiction des gènes essentiels chez certains organismes vivants tels que les SRB, Nous allons utiliser les techniques d'extraction des caractéristiques à partir des séquences de protéines et de nucléotides et les algorithmes d'apprentissage automatique pour mettre sur pied une méthode de prédiction de gènes essentiels nommée EGPS (essential gene prediction system). EGPS est un système de modèle intelligent conçu grâce aux forêts aléatoires (random Forest) pour la classification des caractéristiques extraites. Les modèles qui meublent EGPS se base sur les sous-groupes de caractéristiques de gènes afin de prédire le statut d'essentialité des autres gènes. Le workflow de notre système est subdivisé en quatre couches principales : La première couche permet d'obtenir les séquences de gènes et l'essentialité de certain par ceux depuis les bases de données KEGG (Encyclopedia of Genes and Genomes) [12] et ePath [13]. La deuxième nous permet de nettoyer les séquences extraites, générer les caractéristiques, regrouper les organismes en famille et sélectionner les caractéristiques les plus pertinentes pour chaque sous-groupe de caractéristiques. La troisième couche est meublée par le processus d'entraînement sur les jeux de données des différents sous-groupes. La dernière couche permet de tester le modèle sur l'ensemble de données non encore découvert et donne les scores obtenus en termes de prédiction, rappel, F1-Score et AUC. Il résulte de l'implémentation de cette architecture des classificateurs donc les performances dépassent

considérablement les performances des classificateurs présents dans la littérature pour la prédiction des gènes essentiels en termes de prédiction, rappel, F1-Score et AUC. Ces classificateurs effectuent également avec une meilleur précision la validation inter-organisme.

Organisation du manuscrit

La suite de ce mémoire est structurée en trois chapitres et une conclusion générale. Cette organisation est décrite comme suit :

Chapitre 1. Généralités sur l'intelligence artificielle et le data mining workflow : dans ce chapitre, nous montrerons de manière générale la notion de data mining workflow et l'intelligence artificielle en mettant en exergue le machine learning et le deep learning ainsi que leur impacte sur la prédiction des gènes essentiels.

Chapitre 2. État de l'art sur la prédiction des gènes essentiels : nous montrerons les méthodes de d'extraction des caractéristiques des gènes ainsi que les différents travaux qui ont déjà été effectués dans le domaine de la prédiction des gènes essentiels.

Chapitre 3. Contribution à la prédiction des gènes essentiels des organismes SRB : dans ce chapitre, nous proposons un nouveau système de prédiction des gènes essentiels des procaryotes SRB (sulfate reducing bacteria) en utilisant les techniques et algorithmes de l'apprentissage automatique.

Conclusion générale : dans cette partie, nous résumons notre travail et présentons quelques indications possibles pour la réalisation des travaux futurs.

I

CHAPITRE

GÉNÉRALITÉS SUR L'INTELLIGENCE ARTIFICIELLE ET DATA MINING WORKFLOW

SOMMAIRE

I.1 - Introduction 5
I.2 - Types d'intelligence artificielle 6
I.3 - Le machine Learning 7
I.4 - Deep Learning 12
I.5 - Data mining workflow 18
I.6 - Conclusion 23

I.1. Introduction

L'intelligence artificielle (IA et AI en anglais pour Artificial Intelligence) est un domaine de l'informatique qui vise à doter les machines d'une intelligence leur permettant de calquer ou imiter l'intelligence humaine. Depuis ses débuts dans les années 1950, l'IA a connu des avancées significatives grâce aux progrès technologiques et à l'accès aux données massives. Aujourd'hui, l'IA est utilisée dans de nombreux domaines tels que la médecine, l'agriculture, la biologie, le transport, etc... Ce concept d'IA est meublé par deux branches principales : le Machine Learning (ML) encore appelé apprentissage automatique et le Deep Learning (DL) encore appelé apprentissage profond. Ces deux branches construisent des modèles qui représentent les données à partir des motifs qui s'y trouvent. Pour extraire ces motifs ou patterns dans les jeux de données, le data mining est la méthode par excellence pour le faire. Dans ce chapitre, nous allons présenter successivement

l'intelligence artificielle de manière globale, ainsi que les concepts de Machine Learning (ML), de Deep Learning (DL) et le concept de data mining workflow.

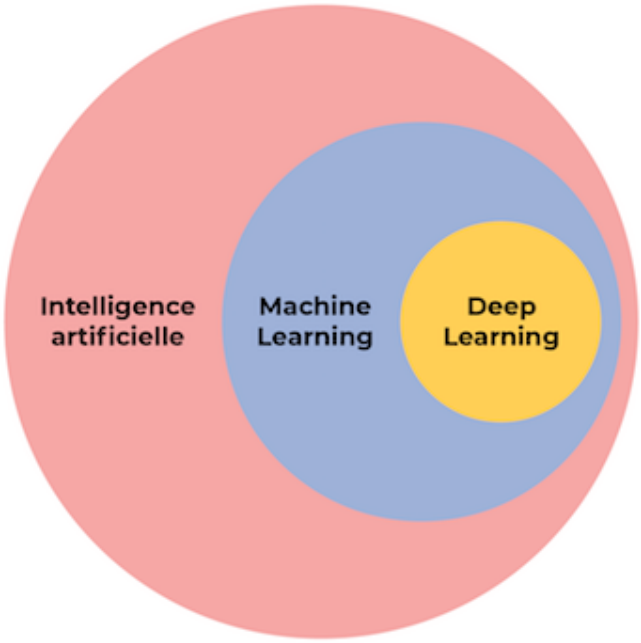


FIGURE 1 – *Intelligence artificielle vs Machine Learning vs Deep Learning :[14]*

I.2. Types d'intelligence artificielle

L'intelligence artificielle qui représente la capacité d'un algorithme à résoudre un problème que seul l'humain pensait être capable de résoudre, ne se limite pas seulement à contrefaire l'intelligence humaine, mais également à effectuer des tâches intellectuelles à un niveau bien plus supérieur à celui d'un être humain dans la majorité des domaines cognitifs similaires. C'est dans cet optique que nous distinguons deux types d'intelligence artificielle à l'instar de l'intelligence artificielle forte et de l'intelligence artificielle faible.

I.2.1. Intelligence artificielle faible

L'IA faible (également connue sous le nom d'IA étroite) est une forme d'intelligence artificielle centrée dans la résolution des tâches spécifiques, à l'instar de la résolution des problèmes d'échec. Contrairement à l'IA générale, ce type d'intelligence artificielle ne fait preuve d'aucune créativité et n'a pas non plus la capacité explicite d'apprendre indépendamment au sens universel. Ses capacités d'apprentissage se reposent à l'apprentissage de modèles de détection (apprentis-

sage automatique) ou à des opérations de comparaison avec de grandes quantités de données. Les avantages d'une IA faible sont particulièrement pertinents dans l'automatisation et le contrôle des processus ainsi que dans la reconnaissance et le traitement de la parole. Par exemple : Reconnaissance de texte et d'image, reconnaissance vocale, traduction de texte, systèmes de navigation, etc...

I.2.2. Intelligence artificielle forte ou l'IA généralisée

l'IA généralisée désigne un paradigme d'IA qui dépasse l'efficience de l'intelligence humaine dans presque tous les domaines cognitifs. Ce type d'IA est dont apte à analyser, interpréter et résoudre les problèmes complexes de la vie quotidienne, y compris la créativité, capacité à comprendre l'humain et sentimentalement capables de se mouvoir d'elle-même. Mais la mise en oeuvre de ce type d'IA nécessite de gros investissements à tous les niveaux.

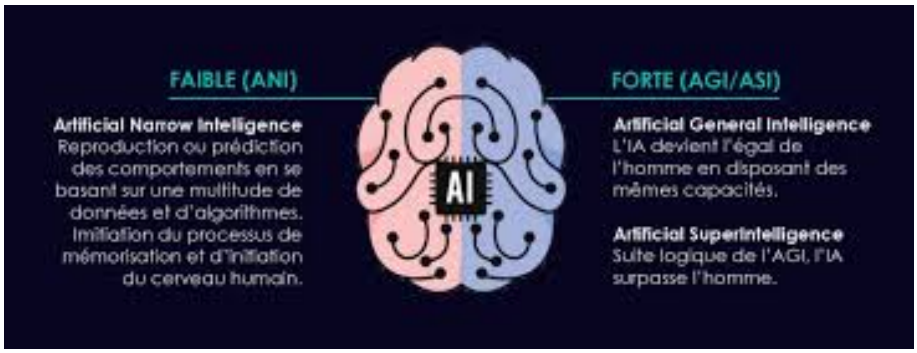


FIGURE 2 – *Intelligence artificielle faible vs intelligence artificielle forte[15]*

I.3. Le machine Learning

Le Machine Learning est un sous-domaine de l'intelligence artificielle qui s'intéresse à la création des machines capables d'apprendre à partir de données et de prendre des décisions sans être explicitement programmées pour le faire. Contrairement aux algorithmes programmés de manière traditionnelle, les algorithmes de Machine Learning peuvent s'adapter à de nouvelles données et améliorer leurs performances avec l'expérience. Le Machine Learning est utilisé dans de nombreux domaines telles que la reconnaissance vocale, la détection de fraudes, la prédiction du comportement des consommateurs, et bien d'autres encore. Les tâches d'apprentissage automatique sont principalement organisées en quatre classes : apprentissage supervisé, non supervisé, semi-supervisé et par renforcement.

I.3.1. Apprentissage supervisé

L'apprentissage supervisé nécessite que ses algorithmes s'entraînent sur un ensemble de données étiquetées, et l'objectif est de mapper de nouvelles données d'entrée à la valeur de sortie cible souhaitée [16]. Les problèmes dans ce type d'apprentissage sont généralement définis ou formatés de la manière suivante : à partir d'un ensemble n d'observations $\{\overrightarrow{x_1}, \overrightarrow{x_2}, \cdots, \overrightarrow{x_n}\} = \{\overrightarrow{x_i}\}_{i=1,\cdots,n}$ appartenant à l'ensemble X, et de leurs étiquettes $\{y_1, y_2, \cdots, y_n\} = \{y_i\}_{i=1,\cdots,n}$ décrites dans un ensemble Y, on cherche à estimer les dépendances entre l'ensemble X et Y afin d'en ressortir un modèle défini par une fonction $y_i = f(x_i) + \varepsilon_i$, où ε_i est un bruit aléatoire. L'algorithme une fois entraîné avec les données étiquetées fournies, devient capable de prédire des étiquettes sur de nouvelles données non annotées.

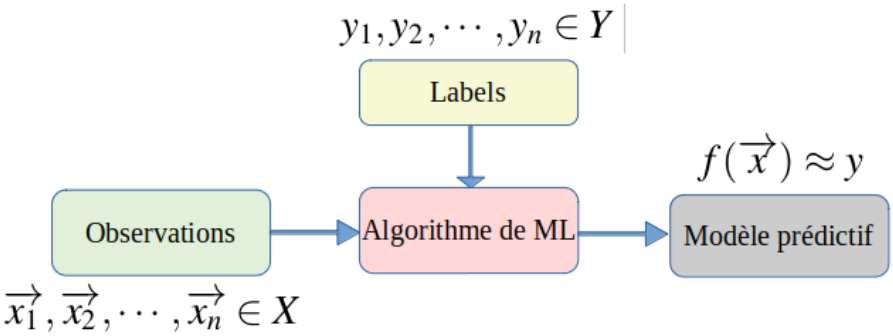


FIGURE 3 – *Apprentissage supervisé*

Ce type d'apprentissage nous permet de résoudre principalement deux types de problèmes :

— Les problèmes de régression : ce sont les problèmes de prédiction de valeurs continues ou réelles sous la base de variable d'entrée.

— Les problèmes de classification : consiste à prédire une variable de sortie discrète, souvent appelée **étiquettes de classe**, à partir d'un ensemble de données d'entrée.

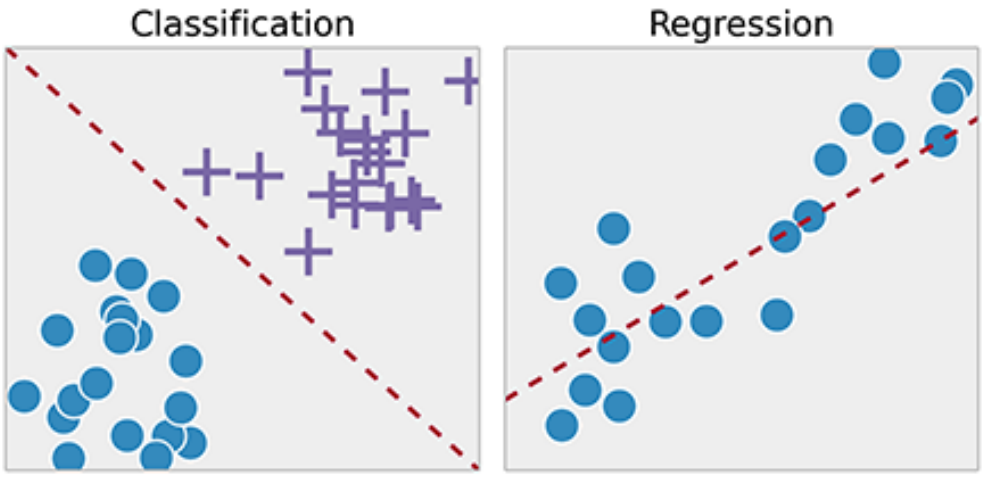


FIGURE 4 – *Régression vs Classification[18]*

Il existe plusieurs algorithmes d'apprentissage supervisé qui sont largement utilisés pour résoudre les problèmes dans ce domaine :

- La Régression Linéaire : est utilisée pour prédire la valeur d'une variable dépendante basée sur la valeur d'une variable indépendante. Il s'agirait par exemple de prédire les ventes annuelles d'un commercial en fonction de son niveau d'études ou de son expérience ;
- La Régression Logistique : est utilisée quand les variables dépendantes sont binaires. Un autre type d'algorithme de régression appelé machine à vecteur de support est pertinent quand les variables dépendantes sont plus difficiles à classifier ;
- les arbres de décision : Cet algorithme permet d'établir des recommandations basées sur un ensemble de règles de décisions en se référant sur des données classifiées. Par exemple, il est possible de recommander sur quelle équipe de football parier en se basant sur des données telles que l'âge des joueurs ou le pourcentage de victoire de l'équipe ;
- Le Random Forest : C'est un algorithme composé d'une collection d'arbres de décision, où chaque arbre de l'ensemble est composé d'un échantillon ou sous-ensemble de données tiré du dataset avec remplacement, appelé échantillon bootstrap. Cet algorithme rend son jugement suite à un vote majoritaire utilisant les résultats de chaque arbre de décision (dans le cas de la classification) et la moyenne des résultats des différents arbre de décision (dans le cas de la régression).
- La machine à vecteur de support (SVM) : c'est un algorithme utilisé pour des problèmes de classification ou de régression. Il utilise une technique appelée l'astuce du noyau pour transformer les données prises en paramètre,

puis sur la base de ces transformations, il trouve une limite optimale entre les sorties possibles ;

— les réseaux de neurones : c'est un calcul (ou algorithme), généralement réalisé à l'aide d'un ordinateur, dont le résultat reproduit ou prévoit aussi fidèlement que possible, le comportement de n'importe quel processus en fonction des facteurs qui déterminent ce comportement ;

I.3.2. Apprentissage non supervisé

L'apprentissage non supervisé est un sous-ensemble du machine leaning qui se charge de la résolution des problèmes dont les données sont sans étiquette. L'idée dans ce type d'apprentissage est de déterminer la structure sous-jacente des données (qui peuvent être une densité de probabilité). Les problèmes de l'apprentissage non supervisé sont formalisés de la manière suivante : étant donné un ensemble n d'observations, $\{\overrightarrow{x_1}, \overrightarrow{x_2}, \cdots, \overrightarrow{x_n}\} = \{\overrightarrow{x_i}\}_{i=1,\cdots,n}$ appartenant à l'ensemble X, on cherche à décrire comment les données sont organisées et d'en extraire des sous-ensemble homogènes. L'algorithme d'entraînement se concentre dans ce cas à trouver seul, les similarités et distinctions au sein de ces données, et à regrouper celles qui partagent des caractéristiques communes.

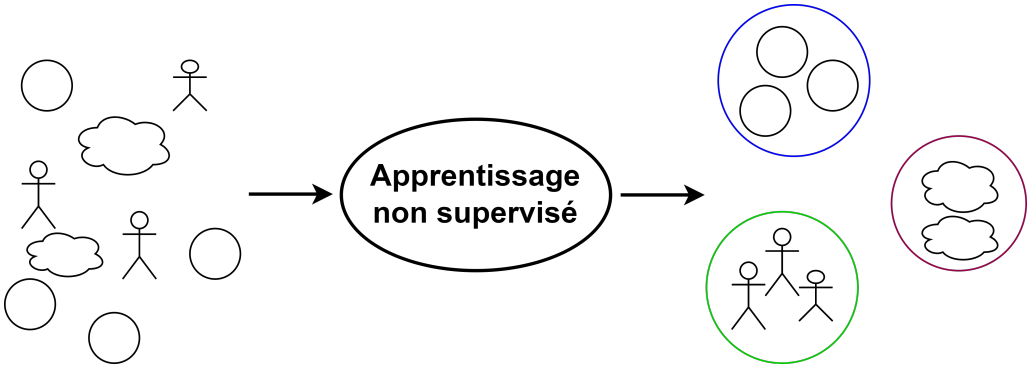


FIGURE 5 – *Apprentissage non supervisé*

Plusieurs algorithmes sont utilisés dans ce sous domaines à savoir :

— Le clustering K-means : c'est un algorithme d'apprentissage utilisé pour résoudre des problèmes de clustering. Il consiste à regrouper des points de données similaires en fonction de leurs caractéristiques ou de leurs similarités. Il aide à identifier les structures et les modèles inhérents aux données. La lettre K désigne le nombre de clusters qu'on souhaite constituer ;

— Règles d'association : Les algorithmes de règles d'association trouvent des relations et des associations fréquentes entre les variables dans les ensembles de données.

— Réduction de la dimensionnalité : C'est un algorithme qui aide à réduire le nombre de variables ou d'entités dans un ensemble de données tout en préservant les informations pertinentes. L'analyse en composantes principales (ACP) est l'une des techniques populaires de réduction de la dimensionnalité.

I.3.3. Apprentissage semi-supervisé

L'apprentissage semi-supervisé implique la formation d'un modèle d'apprentissage à l'aide d'un ensemble de données partiellement annotées, comprenant quelques données annotées et de nombreuses données non annotées [19]. Autrement dit certaines données sont étiquetées tandis qu'un ensemble de données plus important ne sont pas étiquetées [17] ; c'est-à dire que parmi les observations $\{\overrightarrow{x_1}, \overrightarrow{x_2}, \cdots, \overrightarrow{x_n}\}$ seulement un petit nombre d'entre elles ont un label Y_i. L'objectif est d'attribuer des annotations en se basant sur la similarité entre les données annotées et les données non annotées. Ce qui positionne l'apprentissage semi-supervisé entre l'apprentissage supervisé qui n'utilise que des données annotées et l'apprentissage non supervisé qui n'emploie que des données non annotées. La combinaison de ces deux ensembles de données permet d'améliorer significativement les résultats des modèles.

I.3.4. Apprentissage par renforcement

L'apprentissage par renforcement est un type d'apprentissage automatique qui favorise la formation d'un algorithme pour prendre des décisions basées sur des récompenses et des punitions. Dans l'apprentissage par renforcement, au lieu de fournir des paires d'entrée et de sortie, nous décrivons l'état actuel du système, spécifions un objectif, fournissons une liste d'actions autorisées et leurs contraintes environnementales pour leurs résultats, et laissons le modèle ML expérimenter le processus d'atteinte de l'objectif par lui-même en utilisant le principe d'essai et d'erreur pour maximiser une récompense [20].

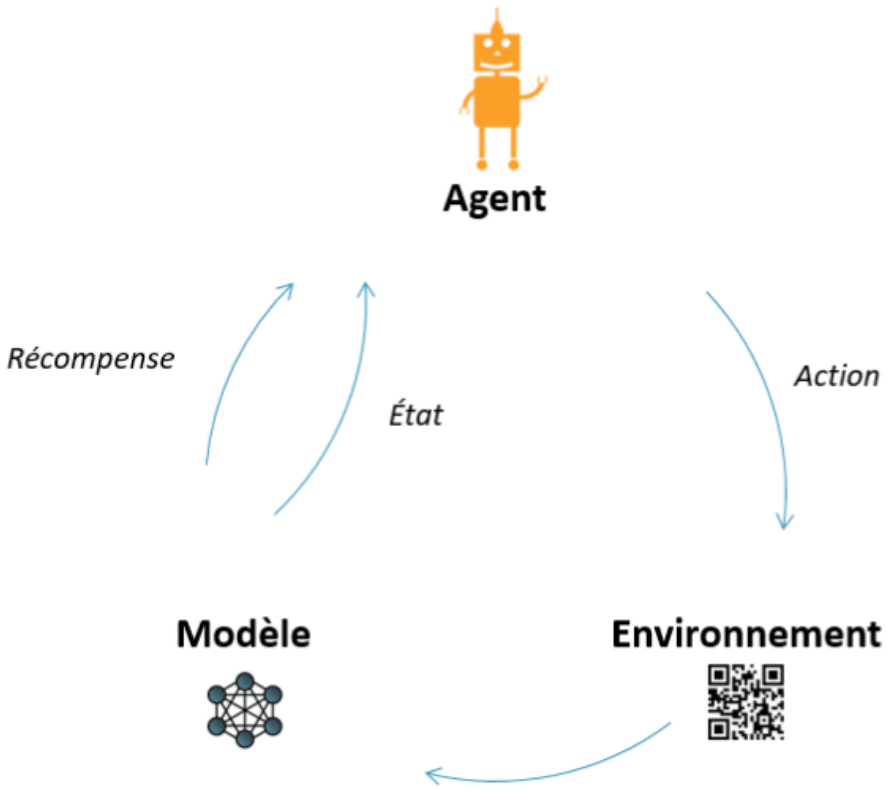


FIGURE 6 – *Apprentissage par renforcement [21]*

L'apprentissage par renforcement décrit par la figure 6 nécessite un certain nombre de concepts et de métriques, dont les principaux sont les suivants :

- Agent : système ou robot qui interagit et agit dans l'environnement ;
- Action a : une action parmi l'ensemble des actions possibles ;
- État s : situation particulière dans laquelle l'agent se trouve ;
- Récompense r(s,a) : Gain positif ou négatif collecté en effectuant l'action a à l'état s. L'objectif est de maximiser les bénéfices totaux d'une politique.

I.4. Deep Learning

L'apprentissage profond (deep learning) est un sous-domaine de l'apprentissage automatique (machine learning) dont le fonctionnement est similaire celui d'un humain. Les algorithmes de ce sous-domaines ont efficacement amélioré les résultats dans divers domaines tels que la vision par ordinateur, la reconnaissance de la parole et la traduction automatique. Grâce à ces algorithmes d'apprentissage profond, il est possible de résoudre de nombreux problèmes dans différents secteurs au rang desquels la santé, le commerce, le transport, la finance et l'énergie en utilisant une quantité de données importantes. Le deep learning utilise des réseaux de neurones

artificiels qui sont conçus en se basant sur les neurones biologiques présents dans le cerveau humain. L'objectif est de simuler la façon dont le cerveau interagit avec les différentes couches neuronales en fournissant ensuite aux algorithmes un apprentissage progressif grâce à une grande quantité de données.

I.4.1. Réseaux de neurones artificiels

Les réseaux de neurones artificiels, également appelés réseaux neuronaux artificiels, sont des systèmes initialement conçus pour fonctionner de manière similaire aux neurones biologiques, mais qui ont depuis évolué vers l'utilisation de méthodes statistiques. L'unité minimale dudit réseau de neurones est le neurone qui reçoit des entrées ou signaux transmis par d'autres neurones et va les relayer vers les autres en utilisant sa fonction d'activation.

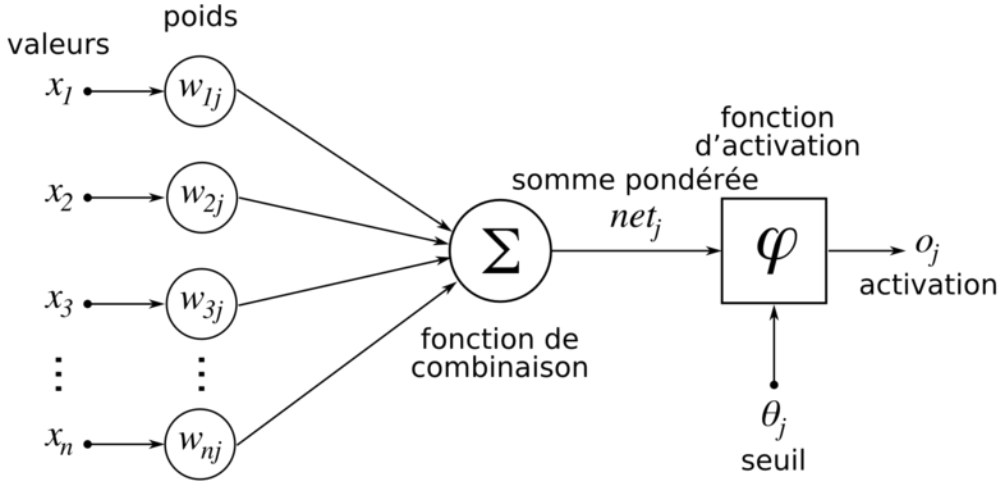


FIGURE 7 – *Réseaux de neurones artificiels [22]*

I.4.2. Les réseaux de neurones récurrents

En 1986, David Rumelhart a introduit les réseaux de neurones récurrents (RNN) qui est une classe de réseaux de neurones, où les connexions entre les unités forment un cycle dirigé. L'un des avantages des RNN est qu'ils peuvent exploiter les corrélations locales dans le temps des données séquentielles, même s'il n'y a pas forcément de corrélation globale. Cela est particulièrement utile pour traiter des données séquentielles qui ont une structure variable dans le temps. Le RNN (Réseau Neuronal Récurrent) est une architecture de réseau neuronal qui utilise la sortie de l'étape précédente comme entrée à l'étape actuelle. Contrairement aux réseaux de neurones traditionnels où chaque entrée/sortie est indépendante des autres, les RNN sont utiles dans des situations où la prédiction du mot suivant d'une phrase nécessite la mémorisation des mots précédents. Une nouvelle tech-

nique appelée RNN a été développée pour résoudre ce problème en utilisant une couche cachée. L'élément le plus important et distinctif des RNN est leur état caché, qui crée un état interne du réseau qui lui permet un comportement temporel dynamique [23]. Pour garder les sorties fiables et cohérentes, les RNN utilisent les mêmes paramètres pour chaque entrée ou couche cachée.

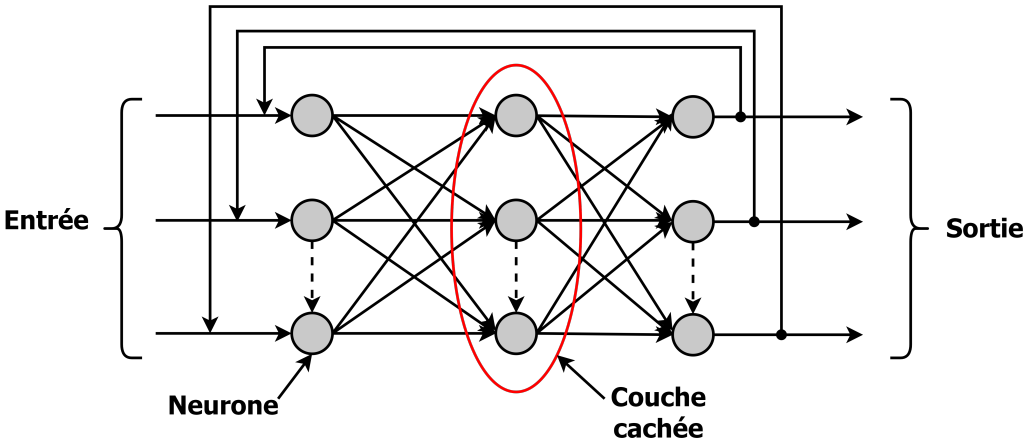


FIGURE 8 – *Exemple de réseau de neurone récurrent [24]*

I.4.3. Les réseaux LSTM(Long Short-Term Memory)

Les réseaux de neurones récurrents (RNN) souffrent d'un inconvénient majeur : leur mémoire à court terme, qui permet de conserver les informations précédentes dans le neurone actuel, se dégrade rapidement lorsqu'il s'agit de séquences plus longues. Afin de résoudre ce problème, les modèles LSTM (Long Short-Term Memory) ont été développés pour prolonger encore davantage la rétention des informations passées. Le LSTM fonctionne en acheminant les données à travers les différentes couches du réseau, de manière similaire au perceptron multicouches (MLP), pour effectuer une prédiction. Comme les RNN, les LSTM possèdent des connexions récurrentes, ce qui signifie que l'état des activations précédentes du neurone au pas de temps précédent est utilisé comme contexte pour générer une sortie. L'architecture des LSTM a été inspirée par une analyse des erreurs de flux dans les RNN existants. Cette analyse a révélé que les décalages temporels prolongés étaient difficiles à atteindre avec les architectures existantes, car l'erreur rétro-propagée avait tendance à exploser ou à décroître de manière exponentielle [25]. Une couche LSTM est composée d'un ensemble de blocs de mémoires interconnectés de manière récurrente. Ces blocs peuvent être considérés comme une version différentiable des puces mémoire d'un ordinateur numérique. Chaque bloc contient une ou plusieurs cellules de mémoire qui sont connectées de manière récurrente, ainsi que trois unités multiplicatives : les portails d'entrée, de sortie et

d'oubli. Ces portails permettent d'effectuer des opérations continues d'écriture, de lecture et de ré-initialisation sur les cellules. Le réseau ne peut interagir avec les cellules qu'à travers ces portails.
Les portails sont la clé de la cellule de mémoire. Ce sont aussi des fonctions pondérées qui régissent en outre le flux d'informations dans la cellule. Il y a trois portails :

- Input : sont des valeurs d'entrée utilisées pour mettre à jour l'état de la mémoire.
- Forget Gate : décide des informations à supprimer de l'état de la cellule. Il examine l'entrée, l'état caché précédent et donne une valeur comprise entre 0 et 1 pour chaque nombre dans l'état de la cellule. 1 – «Retenir complètement », 0 – « Oublier complètement »..
- Output : est chargé de renvoyer la sortie en fonction de l'entrée et de la mémoire de la cellule.

Une cellule de mémoire a des paramètres de poids pour l'entrée, la sortie, ainsi qu'un état interne qui est construit par l'exposition aux étapes de temps d'entrée :

- Poids des sorties : est utilisé pour pondérer la sortie du dernier pas de temps.
- Poids des entrées : est utilisé pour pondérer l'entrée pour le pas de temps actuel.
- État interne : est utilisé dans le calcul de la sortie pour ce pas de temps.

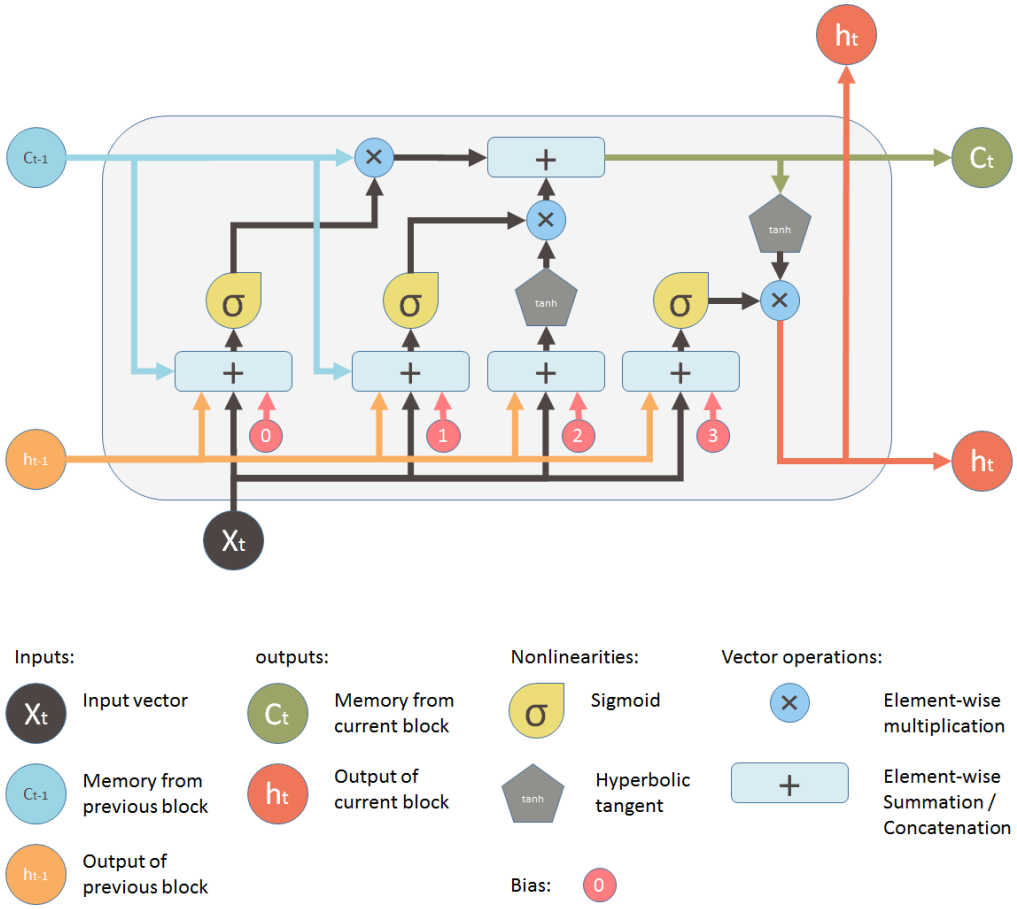


FIGURE 9 – *Architecture des Long Short-Term Memory [26]*

I.4.4. Réseaux de neurones convolutifs

Le réseaux de neurones convolutifs est l'algorithme le plus populaire et le plus couramment utilisé dans le domaine de l'apprentissage en profondeur [27, 28]. Les CNN sont particulièrement adaptés à la reconnaissance d'images grâce à l'utilisation de la convolution, un outil mathématique simple largement utilisé dans le traitement d'images. La convolution agit comme un filtre en définissant une taille de fenêtre qui se déplace à travers l'image. Cette fenêtre commence en haut à gauche de l'image et se déplace d'un certain nombre de cases vers la droite (le pas) jusqu'à ce qu'elle atteigne le bord de l'image, puis elle se déplace d'un pas vers le bas et continue ainsi jusqu'à ce que toute l'image ait été parcourue. Les CNN sont largement utilisés dans plusieurs domaines différents, y compris le traitement de la parole, la reconnaissance faciale, la vision par ordinateur [29] etc. Le principal avantage de CNN par rapport à ses prédécesseurs est qu'il identifie automatiquement les fonctionnalités pertinentes sans aucune supervision humaine [30]. Les CNN ont une architecture composée de deux blocs principaux.

Le premier bloc joue un rôle essentiel dans ce type de réseaux de neurones, car il agit comme un extracteur de caractéristiques. Pour ce faire, il utilise des opérations de filtrage par convolution pour effectuer une correspondance de modèles. La première couche applique plusieurs noyaux de convolution pour filtrer l'image et générer des "feature maps". Ces dernières sont ensuite normalisées à l'aide d'une fonction d'activation et/ou redimensionnées. Ce processus peut être répété plusieurs fois en filtrant les "feature maps" obtenues avec de nouveaux noyaux, ce qui génère de nouvelles "feature maps" à normaliser et redimensionner. Ce cycle peut être répété plusieurs fois. Finalement, les valeurs des dernières "feature maps" sont regroupées dans un vecteur. Ce vecteur représente la sortie du premier bloc et sert d'entrée au deuxième bloc.

Le deuxième bloc, contrairement à un CNN typique, se trouve en réalité à la fin de tous les réseaux de neurones utilisés pour la classification. Les valeurs du vecteur d'entrée subissent une transformation à l'aide de plusieurs combinaisons linéaires et fonctions d'activation, ce qui génère un nouveau vecteur en sortie. Ce dernier vecteur contient un élément pour chaque classe : l'élément i représente la probabilité que l'image appartienne à la classe i. Chaque élément de ce vecteur est donc compris entre 0 et 1, et la somme de tous les éléments est égale à 1. Ces probabilités sont calculées par la dernière couche de ce bloc (et donc du réseau), qui utilise une fonction logistique (pour la classification binaire) ou une fonction softmax (pour la classification multi-classe) comme fonction d'activation.

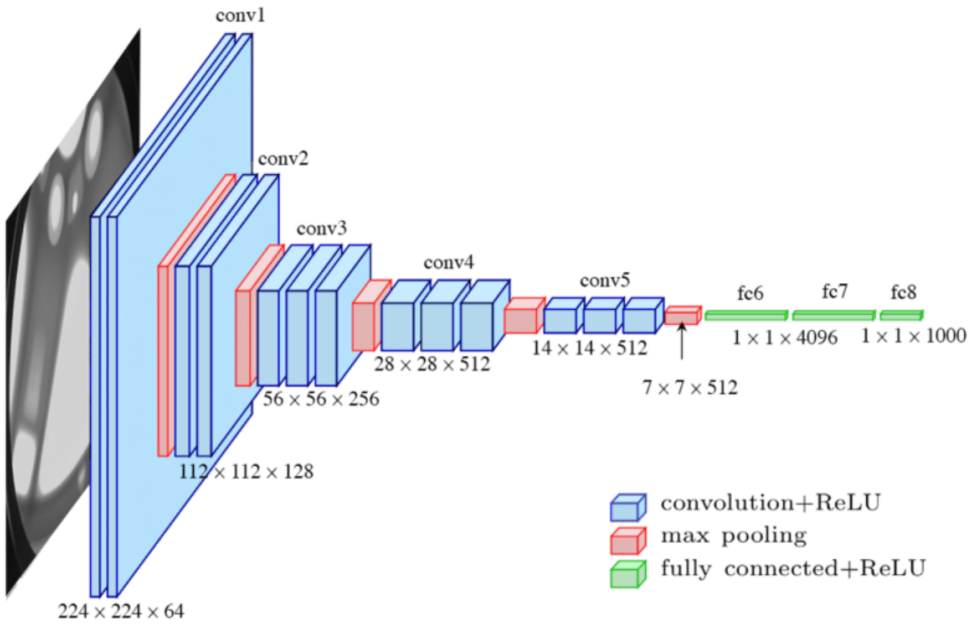


FIGURE 10 – *Architecture d'un réseau de neurone convolutif [31]*

I.5. Data mining workflow

Avec l'avènement de l'intelligence artificielle, la donnée est un élément d'une importance capitale. De par leurs variétés et la rapidité d'accumulation, l'on se retrouve avec une énorme collection de données à analyser et à comprendre afin de les utiliser. Face à cette situation, mettre sur pied un instrument d'analyse offrant des méthodes capables d'extraire des informations utiles à partir de ces données serait d'une aide salvatrice pour les ingénieurs de l'analyse de données. La méthode par excellence depuis plusieurs décennies est le data mining ou science de données. Le data mining consiste à rechercher et à extraire de l'information (utile et inconnue) dans des gros volumes de données sauvegardées dans les bases de données ou dans les entrepôts de données. Les débuts du data mining depuis les années 1990 sont favorisés par la naissance des nouvelles technologies qui améliorent la puissance de calcul des ordinateurs.Les outils du data mining incluent de puissantes fonctionnalités statistiques, mathématiques et analytiques dont l'objectif principal est d'analyser de vastes ensembles de données pour identifier les tendances, les modèles et les relations, pour des prises de décisions et une planification éclairée.

I.5.1. Fonctionnement du data mining

L'exploration de données est généralement effectuée par des data scientists et d'autres professionnels compétents en analyse de données. Mais cela peut également être fait par des analystes commerciaux et du personnel qui ont une bonne compréhension des données et travaillent en tant que data scientists dans l'organisation. Ses principaux éléments sont l'apprentissage automatique et l'analyse statistique, ainsi que les tâches de gestion des données effectuées pour préparer les données à analyser. L'utilisation des outils d'intelligence artificielle (IA) a permis d'automatiser une grande partie du processus et de faciliter l'exploration d'ensembles de données massives (par exemple, des bases de données de clients, des enregistrements de transactions). Le processus d'exploration des données est composé en cinq étapes comme le montre le figure suivante (figure 11) :

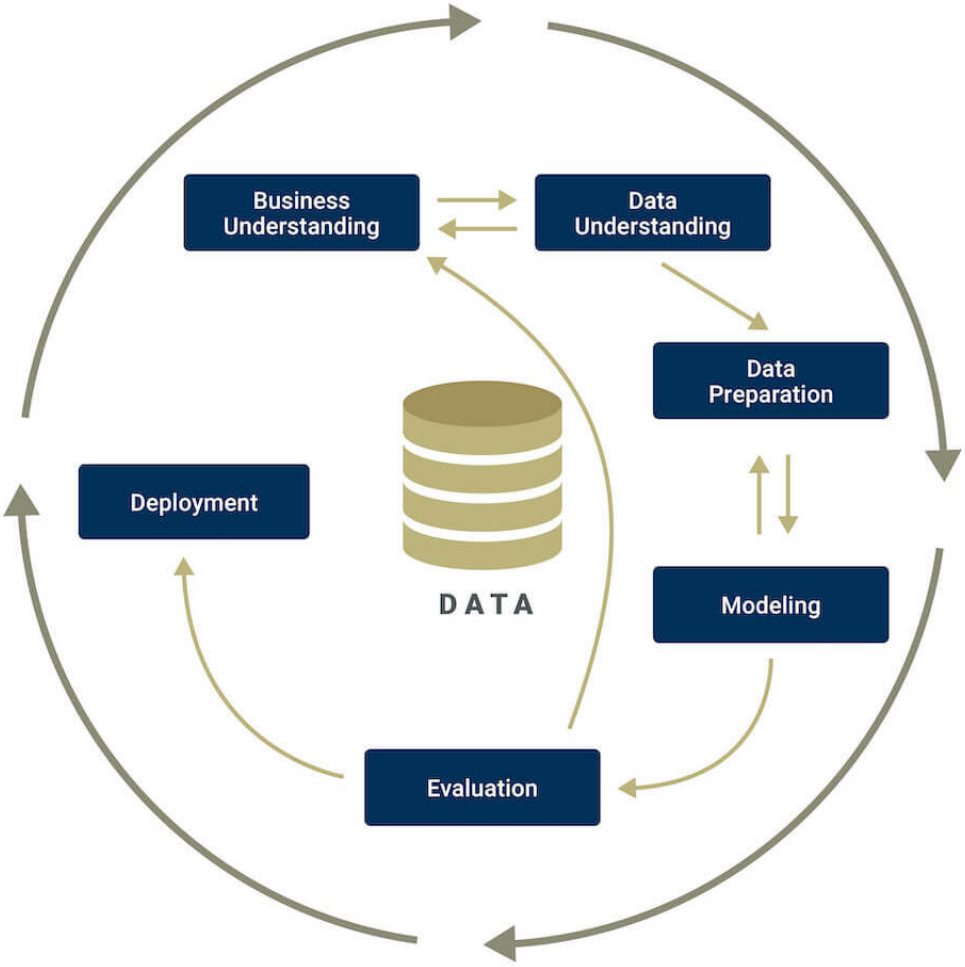


FIGURE 11 – *Fonctionnement du data mining [32]*

— **Compréhension du problème :** Avant que des données ne soient touchées, extraites, nettoyées ou analysées, il est important de comprendre l'entité sous-jacente et le projet en cours. Définir également les objectifs à atteindre pour la résolution du problème.

— **La collecte des données :** Cette phase consiste à collecter les données qui seront soumises à l'analyse. Ces données peuvent être situées dans divers systèmes sources, tels des entrepôts de données qui sont de plus en plus couramment utilisés dans les environnements de big data. Ces données sont également récoltées de plusieurs sources externes. Ces lieux de stockage contiennent un mélange de données structurées (par exemple, des tables de bases de données) et non structurées (par exemple, des documents texte, des images, des vidéos). Quelle que soit l'origine des données, un data scientist se charge de les déplacer fréquemment vers un entrepôt de données pour les étapes ultérieures du processus.

— **Préparation des données :** Cette phase est l'une des phases primordiales du processus. Elle consiste à effectuer un ensemble de traitements sur les données afin de les rendre exploitables. Elle commence par l'exploration, le profilage et le pré-traitement des données, suivis d'un travail de nettoyage des données pour corriger les erreurs et autres problèmes de qualité des données. Ces problèmes sont entre autre les doublons dans les données, les incohérences, les enregistrements incomplets ou les formats obsolètes.
— **Modélisation :** Après la phase de préparation des données, vient la phase d'extraction des informations. Cette étape consiste à sélectionner la technique d'exploration de données appropriée et implémenter un ou plusieurs algorithmes pour effectuer l'exploration. Ces algorithmes sont des algorithmes de machine learning qui vont s'entraîner avec ces données afin de rendre le processus de prévision plus rapide.
— **Évaluation :** Une fois l'entraînement des modèles d'extraction des informations terminé, vient la phase d'évaluation des performances du ou des modèles de données. Les résultats de l'analyse peuvent être agrégés, interprétés et présentés aux décideurs qui ont été largement exclus du processus d'exploration de données jusqu'à présent. À cette étape, les organisations peuvent choisir de prendre des décisions en fonction des résultats.

Cette série d'étapes liées au traitement des données grâce au data mining, constitue le **data mining workflow**. Le data mining workflow, également connu sous le nom de processus de fouille de données, est une séquence d'étapes organisées qui guide les analystes de données dans l'exploration et la découverte d'informations utiles à partir de grandes quantités de données.

I.5.2. Techniques du data mining

L'exploration de données utilise un certain nombre d'algorithmes et diverses autres techniques pour convertir de gros volumes de données en sortie utile. Les techniques d'exploration de données les plus populaires sont les suivantes :

— **Les règles d'association :** Cette technique consiste à explorer les données afin d'extraire les patterns. Ces règles d'association sont des instructions $si \cdots alors$ qui identifient les relations entre les éléments de données. Des critères de support et de confiance sont utilisés pour évaluer les relations. Le support mesure la fréquence à laquelle les éléments liés apparaissent dans un ensemble de données, tandis que la confiance reflète le nombre de fois qu'une déclaration $si \cdots alors$ est exacte. Ce sont les méthodes très sollicitées dans le domaine du marketing et de la distribution. Elles peuvent égale-

ment s'appliquer à différents secteurs d'activités, pour lesquels il est intéressant de trouver le regroupement d'éléments qui se présentent le plus souvent ensemble et de générer des règles d'association. **Apriori** et **FP-Growth** sont des algorithmes populaires pour l'exploration de règles d'association.

— **Clustering :** Cette technique est utilisée lorsque nous n'avons pas assez d'informations sur les différents types d'objets de données impliqués dans une population. Ainsi le type d'apprentissage approprié est l'apprentissage non supervisé qu'il essaie de trouver le groupe d'objets de données qui ont des similitudes les uns avec les autres sans tenir compte d'une étiquette cible spécifique. Par conséquent, il n'y a pas de classes prédéfinies contrairement à la classification. K-means, classification hiérarchique (Hierarchical clustering) etc... sont des algorithmes de clustering largement utilisés.

— **Classification :** Cette technique est utilisée lorsque les données doivent être classées en différents groupes en fonction d'un attribut cible. Par conséquent, les classificateurs prédisent l'étiquette cible pour chaque enregistrement à l'aide des attributs d'entrée. Certaines des techniques de classification les plus connues sont : les arbres de décision, les réseaux de neurones, les K plus proches voisins (K-Means), les machines à vecteurs de support (SVM), les méthodes bayésiennes.

— **Régression :** Cette technique est utilisée pour modéliser et analyser les relations entre les variables dépendantes et indépendantes. Elle aide à prédire des valeurs numériques continues. Les algorithmes de régression linéaire, de régression logistique et de régression polynomiale sont des techniques de régression couramment utilisées.

I.5.3. Importance du data mining

La fouille de données est un processus essentiel de la science des données car elle permet aux ingénieurs de la science de données de mieux comprendre leur ensemble de données. Ce processus est d'une importance capitale dans l'analyse des données dans plusieurs domaines pour des raisons suivantes :

— Prise de décision à partir d'énormes quantités de données : Le data mining permet d'extraire des connaissances et des modèles cachés à partir des données. Il aide les organisations à prendre des décisions éclairées basées sur des informations factuelles plutôt que sur des suppositions ou des intuitions. Cela peut conduire à des décisions plus efficaces et plus rentables.

— Détection de modèles et de tendances : Le data mining permet de découvrir des modèles, des corrélations et des tendances significatives dans les don-

nées. Ces informations peuvent aider les organisations à identifier les opportunités, à anticiper les comportements futurs, à détecter les changements de marché et à prendre des mesures préventives ou proactives.

— Prévision et planification : En analysant les données historiques et en identifiant les relations entre les variables, le data mining peut être utilisé pour prévoir les résultats futurs et établir des plans et des stratégies en conséquence. Cela peut être utile dans la gestion des stocks, la prévision de la demande, la planification financière, etc.

— Segmentation et ciblage : Le data mining permet de regrouper les individus ou les objets en fonction de leurs caractéristiques communes. Cela permet aux organisations de mieux comprendre leurs clients, de segmenter le marché en groupes homogènes, d'adapter les offres et les campagnes de marketing en conséquence, et de cibler les publicités de manière plus précise.

— Personnalisation et recommandation : Le data mining permet de construire des systèmes de recommandation personnalisés en analysant les préférences, les comportements et les historiques d'achat des utilisateurs. Cela améliore l'expérience des utilisateurs en leur fournissant des recommandations pertinentes et en augmentant les taux de conversion et de fidélité.

I.5.4. Quelques domaines d'application du data mining

La fouille de données peut être appliquée à tous les secteurs qui génèrent des données et souhaitent en tirer profit. En effet, l'accès aux données est l'élément majeur pour apporter les réponses à plusieurs questions d'un domaine. Voici quelques exemples de la façon dont l'exploration de données est utilisée dans des industries spécifiques.

— **En santé :** Depuis de nombreuses années, l'intégration de l'exploration de données dans les soins de santé a permis aux médecins de bénéficier de méthodes de traitement plus efficaces en utilisant des données extraites d'essais cliniques et d'études de patients. Les hôpitaux et les cliniques peuvent ainsi améliorer les résultats et la sécurité des patients, tout en réduisant les coûts et les délais de réponse.

— **Médias et télécommunications :** Les entreprises du secteur des médias et des télécommunications ont accès à une énorme quantité de données sur les préférences des consommateurs, telles que les émissions qu'ils regardent, les forfaits internets auxquels ils souscrivent. Grâce à ces données, ces entreprises peuvent orienter leur programmation en fonction des goûts des consommateurs, de leur région ou d'autres facteurs pertinents. Elles peuvent

même recommander des contenus à consommer, une pratique maîtrisée par des entreprises telles que Orange Cameroun , MTN Cameroun, youtube etc...

— **En bioinformatique :** Le data mining joue un rôle important dans le domaine de la bioinformatique. En effet, il est utilisé pour extraire et analyser des informations sur les séquences, les molécules, l'expression des gènes afin de comprendre le fonctionnement de certains processus biologiques.

I.6. Conclusion

Dans ce chapitre, nous avons expliqué le fonctionnement du Machine Learning et du Deep Learning. Pour choisir entre ces deux approches en intelligence artificielle, il est important de considérer le problème à résoudre. Si les données sont peu structurées et que l'architecture ne comporte qu'une couche cachée, le Machine Learning est préférable. En revanche, si les données sont nombreuses et variées (images, texte, sons...) et que l'architecture comporte plusieurs couches cachées, le Deep Learning est plus adapté grâce aux réseaux de neurones. De plus, si l'on doit extraire des caractéristiques pour guider la prédiction (Feature extraction), le Machine Learning est recommandé. Mais si l'on ne sait pas quelles caractéristiques sont nécessaires pour la prédiction (par exemple pour classifier des images), le Deep Learning peut effectuer cette extraction automatiquement grâce aux pixels.

II

CHAPITRE

ÉTAT DE L'ART SUR LA PRÉDICTION DES GÈNES ESSENTIELS

SOMMAIRE

II.1 - Introduction 24
II.2 - Vocabulaire de quelques termes de la biologie 25
II.3 - Présentation du matériel génétique 26
II.4 - Approches de prédiction des gènes essentiels 30
II.5 - Conclusion 39

II.1. Introduction

En biologie, la génétique est la discipline fondamentale qui nous aide à comprendre les mécanismes de l'hérédité, autrement dit, elle se charge de la transmission des caractères ou informations génétiques d'une génération à l'autre. Elle passe en revue les processus et les techniques qui déterminent la variation des caractéristiques et de traits hérités chez les êtres vivants, des micro-organismes, y compris les êtres humains. La génétique contrôle également les mécanismes moléculaires de la réplication de l'ADN, de la transcription de l'ADN en ARN et de la traduction de l'ARN en protéines. Elle se charge aussi des mutations génétiques, qui sont des changements dans la séquence de l'ADN, et leur rôle dans la variation génétique et l'évolution des espèces. La pierre angulaire dans cette discipline est le concept de **gène**, qui est l'unité de base de l'information génétique. Lorsque ces informations sont perturbées de manière défavorable, cela peut entraîner des maladies génétiques[36]. Les gènes qui sont d'une importance cruciale pour un organisme, nous permettent d'avoir une pléthore d'informations sur la souche originelle de cet organisme. Grâce aux avancées technologiques, le séquençage du

génome a évalué donnant naissance à d'énormes quantités de données ces dernières décennies. Face à cette situation, les chercheurs ont mis et mettent tout en œuvre pour concevoir des modèles de ML capable de déterminer les gènes essentiels parmi les gènes d'un organisme, afin de comprendre de mieux en mieux le rôle des gènes dans la biologie, la santé et l'évolution des organismes vivants. Les travaux qu'ils ont proposés jusqu'ici ont porté leur fruit et ont permis de mettre sur pied certaines solutions qui permettent de prédire le statut d'essentialité des gènes des organismes. Ces différents travaux que nous présenterons ont été faits pour pouvoir extraire les caractéristiques des gènes d'une part et de concevoir des modèles prédictifs de statut d'essentialité des gènes essentiels d'autre part. Ainsi, dans la suite de ce chapitre nous présenterons tout d'abord les matériaux génétiques, ensuite les techniques d'extraction des caractéristiques des gènes, et enfin les approches qui ont été mises sur pied pour prédire le statut d'essentialité des gènes des organismes.

II.2. Vocabulaire de quelques termes de la biologie

La définition de quelques termes nous permet la bonne compréhension des éléments de base de la génétique :

- Le génome : Ensemble de l'information génétique d'un organisme contenu dans chacune de ses cellules sous la forme de chromosomes
- Chromosome : Structure de l'ADN en forme de brin et protéine contenant les informations génétiques.
- Chromosomes homologues : sont des chromosomes de même taille, de même forme et comportant le même agencement de gènes.
- Cellule diploïde ($2n$) : Cellule qui contient deux ensembles de chromosomes homologues.
- Cellule haploïde : (n) : Cellule qui ne contient qu'un seul ensemble de gènes.
- Chromosomes sexuels : Un des deux chromosomes ($XouY$) qui détermine le sexe d'un organisme.
- Autosome : Chromosome qui n'est pas un chromosome sexuel.
- Caryotype : Image micrographique d'un ensemble diploïde de chromosomes regroupés par paires.
- organisme unicellulaire : organismes constitués d'une seule cellule
- organisme multicellulaire : organismes constitués de plusieurs cellules.

II.3. Présentation du matériel génétique

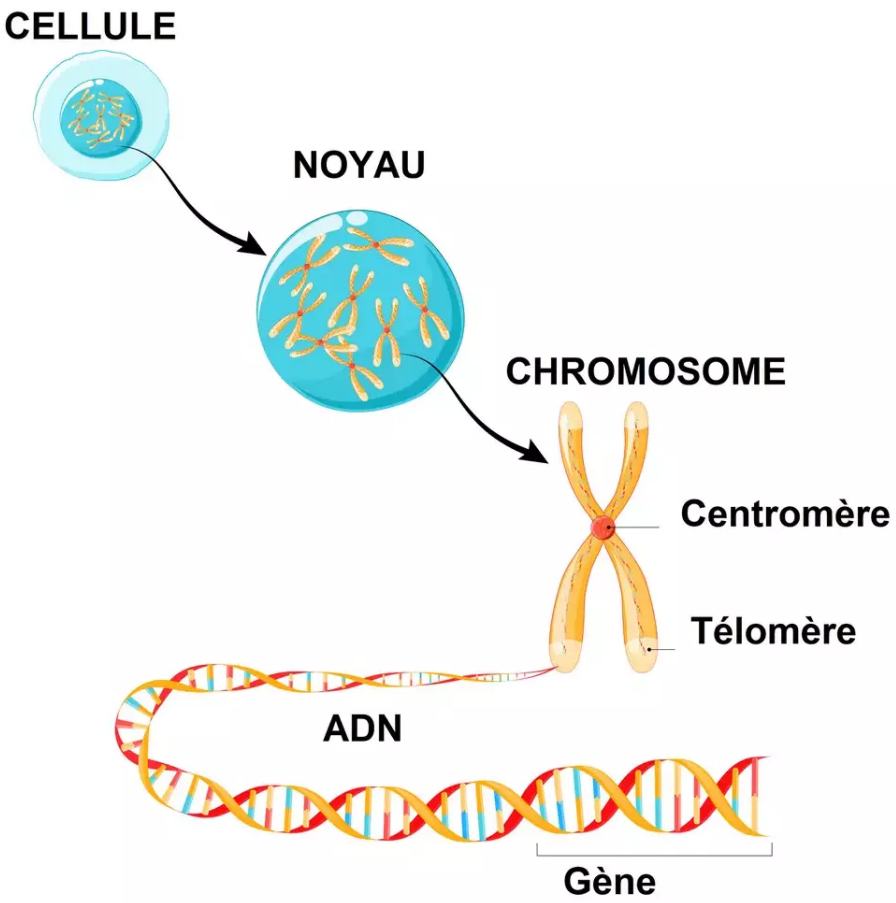


FIGURE 12 – *Éléments du matériel génétique[33]*

II.3.1. Cellule

Les cellules sont des composantes essentielles de notre corps, formant tous les organes et tissus nécessaires à son bon fonctionnement. Parmi ces organismes, certains peuvent être unicellulaire et d'autres multicellulaires. Malgré leurs tailles variables, toutes les cellules ont une structure similaire et interagissent entre elles. Il est important de se concentrer sur cette unité microscopique fondamentale. Il est estimé que le corps humain contient des milliards de cellules. La cellule représente l'unité fondamentale structurelle et fonctionnelle des êtres vivants. Ces cellules comprennent plusieurs organites cellulaires qui assument diverses fonctions vitales telles que le métabolisme, le mouvement, la croissance, la reproduction et la transmission des gènes. C'est une entité vivante autonome qui maintient une coordination avec les autres cellules. selon les chercheurs tels que [36], Il existe deux types de cellules : les cellules procaryotes et les cellules eucaryotes. Les cellules

procaryotes sont des cellules simples, comme les bactéries, qui ne possèdent pas de noyau et dont l'ADN est présent dans le cytoplasme. Les cellules eucaryotes, en revanche, comprennent des organismes plus complexes, comme les plantes, les animaux et les humains, et possèdent un noyau contenant de l'ADN. Une cellule est constitué de plusieurs entités telles que cytoplasme, le noyau etc... Le noyau est le domaine qui contient le matériel génétique de la cellule (gènes et chromosomes), qui contient toutes les instructions sur le fonctionnement de la cellule et sur le contrôle de la division et de la reproduction cellulaire.

II.3.2. Chromosomes

Les chromosomes sont les structures présentes dans le noyau des cellules qui renferment l'information génétique d'un organisme. Ils ont une forme spécifique et un nombre constant pour une espèce donnée. Les chromosomes sont des paquets de matériel génétique présents dans nos cellules, et ils constituent le fondement de notre biologie en tant qu'organisme. Ils dictent la séquence des événements qui conduisent au développement des organismes matures, en particulier par la transmission des caractères héréditaires.

Chaque chromosome est une entité composée d'ADN et est situé dans le noyau des cellules eucaryotes et dans le cytoplasme pour les cellules procaryotes. Il contient, sous une forme codée, la programmation des caractères spécifiques de l'espèce. Chaque espèce possède un ensemble de chromosomes différents. Si cet ensemble de chromosomes est présent une seule fois par cellule, la cellule est dite haploïde. Si cet ensemble est présent deux fois par cellule, la cellule est dite diploïde.

Les chromosomes sont des structures composées d'ADN et de protéines. Ils contiennent des segments d'ADN appelés gènes, qui portent l'information nécessaire à la synthèse des protéines. Lorsque le processus de duplication et la division du matériel génétique appelé mitose (ou caryocinèse), l'enchevêtrement de fils commence, un phénomène de condensation progressive se charge de montrer chacun des chromosomes.

II.3.3. Acide désoxyribonucléique (ADN)

L'ADN est une molécule qui contient l'information génétique essentielle pour le développement et le fonctionnement d'un organisme. La structure de l'ADN est composée de deux brins enroulés autour de l'un et de l'autre, formant une structure en double hélice qui ressemble à une échelle torsadée. Chaque brin est constitué d'une alternance de groupes sucre (désoxyribose) et de phosphate. A chaque sucre est attachée l'une des quatre bases : adénine (A), cytosine (C), guanine (G) ou

thymine (T). Les deux brins sont reliés par des liaisons chimiques entre les bases : des liaisons adénine avec la thymine et des liaisons cytosine avec la guanine. La séquence des bases le long du squelette de l'ADN code des informations biologiques, telles que les instructions pour fabriquer une protéine ou une molécule d'ARN [37].

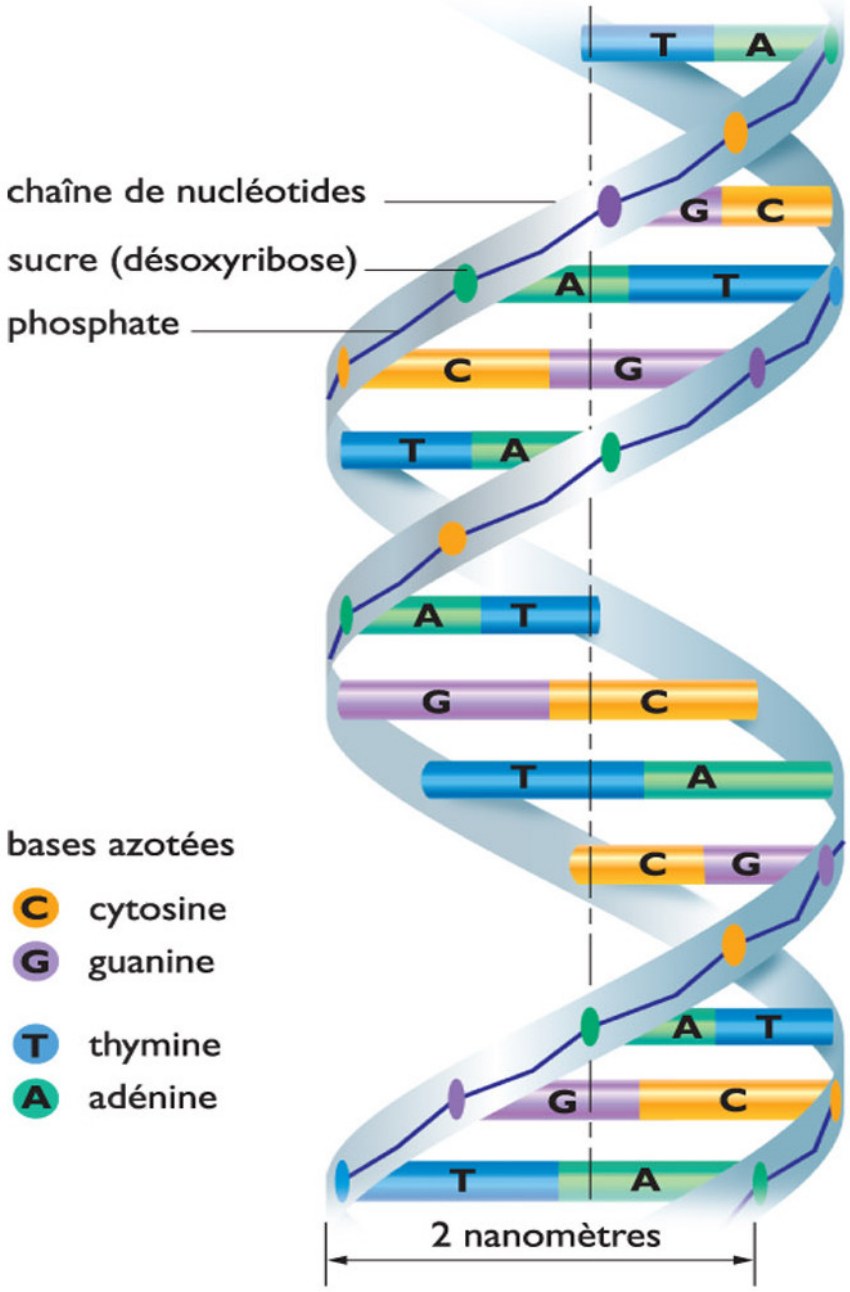


FIGURE 13 – *LA STRUCTURE DE LA MOLÉCULE D'ADN [38]*

II.3.4. Gènes

Les gènes sont des segments spécifiques des molécules d'ADN situés sur les chromosomes. L'ensemble des gènes d'un individu forme le génome, l'expression

des caractères qu'il gouverne, telle qu'on peut l'observer constitue le phénotype. Leur position sur le chromosome est appelée **locus**. Les organismes possèdent des paires de chromosomes, et chaque gène est présent en deux exemplaires dans leurs cellules. Ces deux copies du même gène sont appelées **allèles** et sont généralement différentes, avec l'une héritée du père et l'autre de la mère. Chaque gène contient une séquence d'ADN qui code pour une fonction ou une caractéristique spécifique. Ils déterminent les traits héréditaires des organismes, tels que la couleur des yeux, la taille, la susceptibilité à certaines maladies, etc. Les gènes sont transmis de génération en génération et sont responsables de la diversité génétique. A partir de l'information qu'ils contiennent, ils synthétisent des protéines indispensables à la vie : c'est la **traduction du code génétique**. C'est ce qui montre l'utilité de ces derniers dans le fonctionnement de notre corps. Par exemple, la myosine est une protéine qui sert à la contraction des muscles. La mélanine protège la peau et lui donne sa couleur. Lorsqu'un gène ou un chromosome est altéré, les protéines concernées sont mal ou pas du tout produites. Par exemple, quand la **myosine** est mal produite à cause d'un gène muté, la personne développe une maladie génétique appelée une myopathie, qui entraîne un dysfonctionnement des muscles.

II.3.5. Importances des gènes essentiels

Les gènes essentiels jouent un rôle fondamental dans le fonctionnement et la survie des organismes vivants. Ces gènes sont indispensables pour le développement normal, la croissance et la reproduction d'un organisme. Leur absence ou leur altération peut entraîner des conséquences graves, voire la mort de l'organisme.

Les gènes essentiels sont impliqués dans des processus biologiques vitaux tels que la régulation du cycle cellulaire, la réparation de l'ADN, la synthèse des protéines et la fonction des organes. Ils sont responsables de la production de protéines clés nécessaires au bon fonctionnement des cellules et des systèmes organiques.

Ces gènes jouent également un rôle crucial dans le maintien de l'homéostasie, c'est-à-dire l'équilibre interne de l'organisme. Ils interviennent dans la régulation des voies métaboliques, la signalisation cellulaire, le contrôle de l'expression génique et la réponse aux stimuli environnementaux.

L'importance des gènes essentiels est également mise en évidence par leur conservation à travers l'évolution. De nombreux gènes essentiels sont conservés chez différentes espèces, ce qui reflète leur rôle fondamental et leur nécessité pour la survie des organismes.

L'étude des gènes essentiels revêt une grande importance en biologie et en médecine. Comprendre ces gènes permet de mieux appréhender les mécanismes

biologiques et les voies moléculaires qui régulent les processus vitaux. Cela peut conduire à l'identification des cibles thérapeutiques pour le développement de médicaments visant à traiter des maladies génétiques, des troubles du développement ou des maladies complexes.

En résumé, les gènes essentiels sont des éléments cruciaux pour le fonctionnement normal des organismes vivants. Leur rôle dans le développement, la croissance, la reproduction et le maintien de l'homéostasie en fait des éléments clés de la biologie et de la santé. L'étude des gènes essentiels ouvre des perspectives prometteuses pour la compréhension des mécanismes biologiques et le développement de thérapies innovantes.

II.4. Approches de prédiction des gènes essentiels

II.4.1. Approches basées sur l'apprentissage automatique supervisé

II.4.1.1. Approches utilisant les machines à vecteurs de support (SVM)

La prédiction des protéines essentielles d'un organisme pathogène est la solution adéquate pour identifier les potentielles cibles médicamenteuses, car l'inhibition de celles-ci serait fatale pour l'agent pathogène. L'identification de ces protéines nécessite l'utilisation de techniques expérimentales complexes qui sont assez coûteuses et chronophages. C'est dans cette optique qu'en 2013, Aditya et Mohtashim [34] ont proposé une méthode de prédiction des protéines essentiels chez les procaryotes. Ils ont utilisé l'algorithme Support Vector Machine pour développer un modèle de prédiction des protéines essentielles chez les procaryotes basé sur les propriétés physico-chimiques des séquences d'acides aminés. Ce classificateur a été conçu sur la base d'un ensemble de 10 vecteurs de descripteurs (DV) physico-chimiques et de 4 vecteurs de descripteurs hybrides calculés à partir de séquences d'acides aminés à l'aide de serveurs PROFEAT et PseAAC. Leur classificateur a été formé à l'aide d'ensembles de données composés de 500 protéines essentielles et 500 non essentielles connues et évalué à l'aide d'un ensemble de validation externe composé de 3 462 protéines essentielles et 5 538 protéines non essentielles. les résultats obtenus par Aditya et Mohtashim [34] sur l'ensemble 13 descripteurs, qui est la combinaison de l'ensemble de descripteurs de composition, de transition et de distribution et de l'ensemble de descripteurs d'auto-corrélation hybride, sont : une précision de 91,2% dans la validation croisée de 10 fois de l'ensemble d'ap-

prentissage et une précision de 89,7% dans l'ensemble de validation externe et de 91,8% et 88,1% en utilisant un ensemble de données différent sur les protéines de levure. Bien que ces chercheurs aient obtenu des résultats acceptables, leur classificateur n'est pas capable de prédire avec précision les gènes d'un organisme qu'il n'a jamais vu.

II.4.1.2. Approches utilisant le classificateur XGBoost

À l'échelle du génome, les gènes essentiels peuvent être déterminés expérimentalement à l'aide d'ARNi ou d'écrans knock-out, mais cela nécessite beaucoup de ressources. Pour palier à ce problème, Olufemi A., Thomas B., Marcus O., Jelili O., Ezekiel A. et Rainer K. [36] ont proposé une nouvelle méthode de prédiction des gènes essentiels basée sur apprentissage automatique pour prédire les gènes essentiels chez Drosophila melanogaster. Ces derniers ont utilisés un total de 27340 caractéristiques obtenus sur la base d'une grande variété d'aspects différents comprenant des séquences de nucléotides et de protéines, des réseaux de gènes, des interactions protéine-protéine, la conservation évolutive et des annotations fonctionnelles. Ils ont utilisés ces caractéristiques pour entraîner cinq algorithmesde ML (GLM. SVM, NNET, RF et XGB) où le XGB a atteint des performances légèrement meilleurs que les autres. L'architecture de la méthode proposée est définie sur la figure suivante (figure 14) :

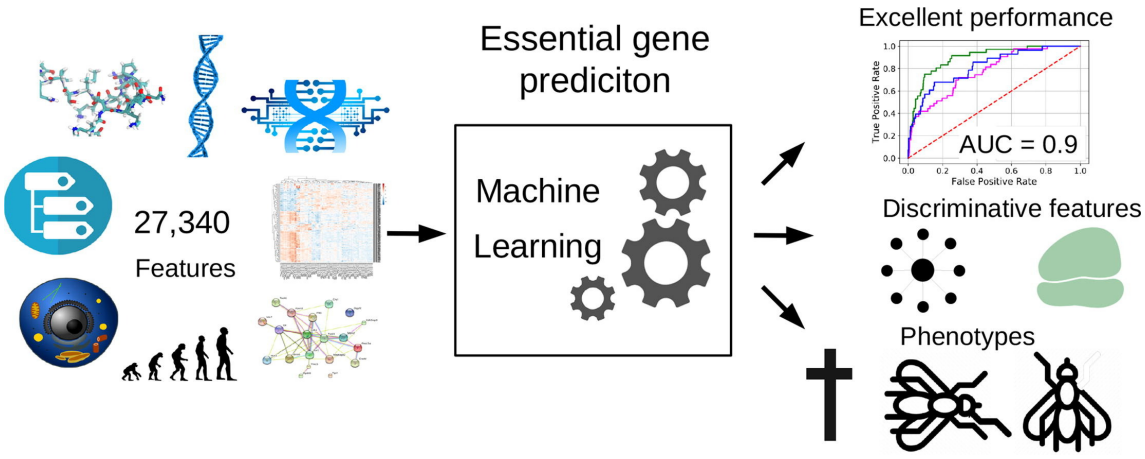


FIGURE 14 – *Architecture du modèle proposé par Olufemi A. et Thomas B. [36]*

En utilisant la validation croisée, les chercheurs ont obtenu une excellente performance de prédiction. Le meilleur modèle a obtenu chez D. melanogaster un ROC-AUC de 0,90, un PR-AUC de 0,30 et un score F1 de 0,34. Cette méthode a été ensuite utilisée pour prédire des gènes essentiels chez l'homme. Cette prédiction chez les hommes les a permis d'évaluer leur approche et on obtenu un ROC-AUC de 0,92, PR-AUC de 0,73 et F1 de 0,64. La limite de cette méthode

est sont incapacité à faire de la validation extra-organisme. Ce qui remet en cause le niveau de généralisation de cette approche.

II.4.1.3. Approches utilisant le classificateur Random Forest et le Gradient Boosting Method

Grâce à l'abondance de séquences génomiques complètes et de jeux de données multi-ohmiques connexes, ainsi qu'aux avancées dans les méthodes d'inactivation des gènes, nous disposons maintenant des outils nécessaires pour annoter et explorer de manière exhaustive les fonctions des gènes et des protéines chez plusieurs organismes eucaryotes et procaryotes. Cette évolution a permis à plusieurs scientifiques tels que (Tulio L. Campos, Pasi K. Korhonen, Robin B. Gasser, and Neil D. Young) [36] de proposer une nouvelle approche de prédiction des gènes essentiels chez les organismes eucaryotes.

Dans cette étude, L. Campos, Pasi K. Korhonen, Robin B. Gasser, and Neil D. Young [36] ont examiné les orthologues des gènes dans une sélection d'espèces eucaryotes, puis ont utilisé une approche d'apprentissage automatique. Ils ont utilisé des caractéristiques dérivées des séquences protéiques et des méthodes de sélection pour prédire les gènes essentiels à la fois au sein des espèces et entre elles. Les résultats ont montré que les modèles d'apprentissage automatique entraînés sur des sous-ensembles de données spécifiques à l'essentialité des gènes ont donné de meilleurs résultats que les estimations aléatoires d'essentialité des gènes pour une espèce donnée. En utilisant le package "protr" de R, ils ont pu extraire 9920 caractéristiques intrinsèques à partir de chaque séquence protéique individuelle. Ce package met en œuvre diverses méthodologies d'extraction de caractéristiques protéiques largement utilisées dans les approches d'apprentissage automatique. Afin de mieux comprendre ce modèle, voici le workflow du modèle qui a été établi (figure 15) :

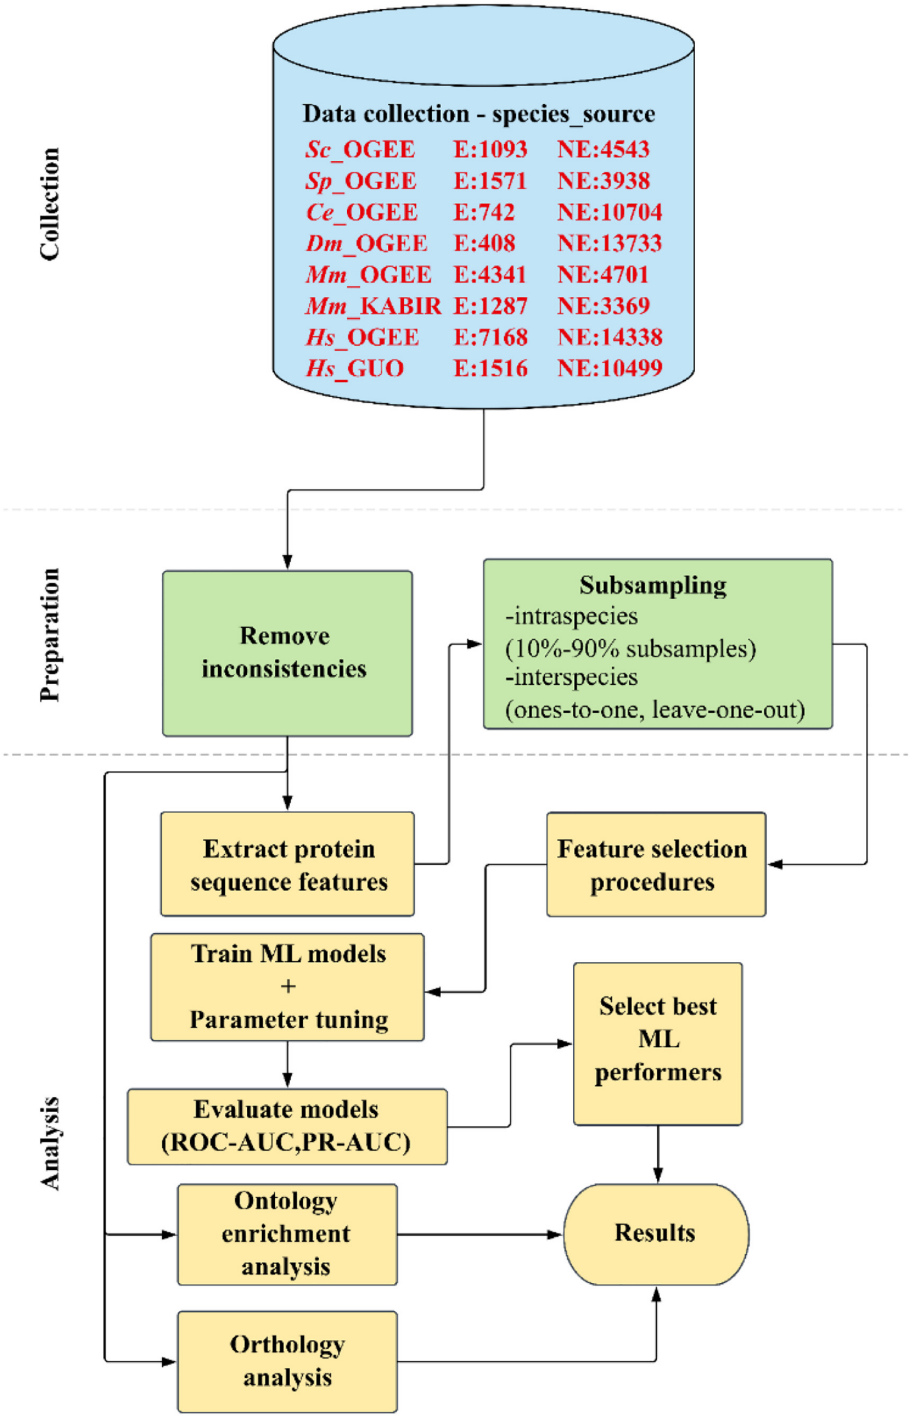


FIGURE 15 – *Workflow du modèle de[36]*

L'étude réalisée par les auteurs démontre que l'utilisation de caractéristiques dérivées de séquences protéiques associées à des ensembles de données génomique fonctionnelle permet aux méthodes d'apprentissage automatique de prédire les gènes essentiels chez les eucaryotes. Les prédictions basées sur les modèles d'apprentissage automatique au sein d'une même espèce étaient fiables, et les pré-

dictions entre ou parmi différentes espèces étaient meilleures que les suppositions aléatoires d'un classificateur par défaut.

Les modèles d'apprentissage automatique utilisés dans cette étude présentent des lacunes en ce qui concerne la gestion des problèmes de déséquilibre d'apprentissage qui se produisent dans la prédiction des gènes essentiels. Cette lacune peut être un facteur qui affecte les performances de ces modèles.

II.4.2. Approche basé sur la méthode d'apprentissage automatique semi-supervisé

Depuis plusieurs décennies, la majorité des méthodes de prédiction des gènes essentiels chez les organismes vivants, sont basées sur les modèles d'apprentissage supervisé. Cependant, ces méthodes peuvent ne pas obtenir le résultat souhaité lorsque les données étiquetées sont insuffisantes. Afin de remédier à ce problème, certains chercheurs tels que (Xiao Liu, Ting He, Zhirui Guo, Meixiang Ren, and Yachuan Luo.) [39] ont proposés un classificateur basé sur la méthode d'apprentissage avec cohérence locale et globale (LGC), qui a été utilisé pour prédire les gènes essentiels de 41 procaryotes. LGC est une méthode d'apprentissage semi-supervisée basée sur des graphes qui peuvent construire un modèle de prédiction en utilisant des informations finies sur les étiquettes et les contraintes. La performance du classificateur proposé par les auteurs (Xiao Liu, Ting He, Zhirui Guo, Meixiang Ren, and Yachuan Luo.) [39] a été évaluée en utilisant la prédiction intra-organisme et la validation de l'exclusion d'une espèce. Les résultats de cette étude indiquent que la méthode proposée peut atteindre des performances de prédiction acceptables avec des données étiquetées limitées. L'architecture de la méthode proposée est définie sur la figure suivante (figure 16) :

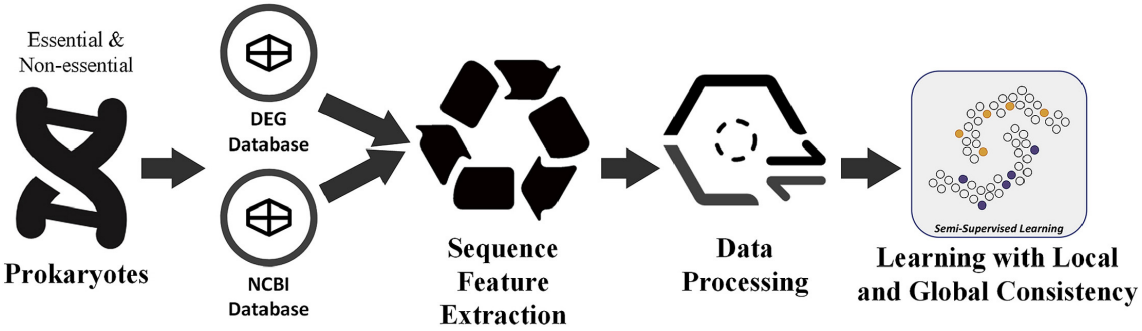


FIGURE 16 – *Architecture du modèle proposé par Xiao L. et Yachuan L. [39]*

Les résultats obtenus par ces auteurs sont classés suivant les deux moyens de prédiction (prédiction intra-organisme et prédiction d'exclusion d'une espèce). Dans les prédictions intra-organismes, le score AUC moyen des 41 organismes est

de $0,723$ lorsque le rapport d'échantillon étiqueté est de 0,5 et que toutes les caractéristiques sont utilisées. Le score AUC des organismes est de $0,697$ lors de l'utilisation des caractéristiques clés sélectionnées.

Cette approche basée sur l'apprentissage automatique proposée dans cette étude présente des problèmes en ce qui concerne la gestion des problèmes de déséquilibre de l'ensemble d'apprentissage quand le ratio entre la quantité de gène essentiel et la quantité de gène non-essentiel est inférieur $0,5$. Cette lacune peut impacter négativement sur les performances de ce modèle quand le ratio est inférieur à $0,5$.

II.4.3. Approche basée sur l'apprentissage en profondeur

II.4.3.1. Approche utilisant les réseaux de neurones à plusieurs couches

Le manque de meilleures performances des modèles de prédiction des gènes essentiels est dû généralement au problème de déséquilibre des données utilisées pendant le processus de formation. C'est ce qui a soulevé une nouvelle problématique qui va retenir l'attention de certains scientifiques tels que (Xue Zhang, Wangxin Xiao, and Weijia Xiao.) [40]. Ces derniers vont proposer une nouvelle approche basée sur l'apprentissage en profondeur, DeepHE, pour prédire les gènes humains essentiels en intégrant des caractéristiques dérivées des données de séquence et du réseau d'interaction protéine-protéine (PPI). Pour l'extraction des caractéristiques, diverses caractéristiques sont extraites pour chaque gène à partir des données de séquences des nucléotides et protéines. Ces deux types de fonctionnalités sont intégrées pour former un réseau de neurones multi-couche. Une technique sensible au coût a été utilisée pour résoudre le problème d'apprentissage déséquilibré lors de la formation du réseau neuronal profond.

DeepHE se compose principalement de deux parties : une partie d'extraction et d'apprentissage de caractéristiques et une partie de classification. Il prend deux types de données en entrée, les données de séquence et le réseau PPI. Au niveau de l'extraction des caractéristiques, plusieurs caractéristiques de séquence pour chaque gène sont extraites de sa séquence de nucléotides et de ses données de séquence de protéines. De plus, une méthode d'intégration, node2vec, est utilisée pour apprendre les caractéristiques sémantiques de chaque gène du réseau PPI. Ces deux types de vecteurs de caractéristiques pour chaque gène sont concaténés ensemble comme entrée du module de classification. Le module de classification est basé sur un réseau de neurones à plusieurs couches qui se compose de plusieurs couches cachées entièrement connectées et d'une couche de sortie. Toutes ses couches cachées utilisent l'excellente fonction d'activation pour l'apprentis-

sage en profondeur, ReLU (unité linéaire rectifiée), et utilisent la technique d'abandon pour éviter le sur-ajustement. Après les couches cachées, la couche de sortie entièrement connectée utilise la fonction sigmoïde comme fonction d'activation. Compte tenu de la nature de la distribution asymétrique du problème de prédiction des gènes essentiels humains, nous explorons une technique sensible au coût pour résoudre le problème d'apprentissage déséquilibré lors de la formation du classificateur en utilisant le poids de la classe. L'architecture dudit modèle est donné par la figure ci-dessous (figure 17) :

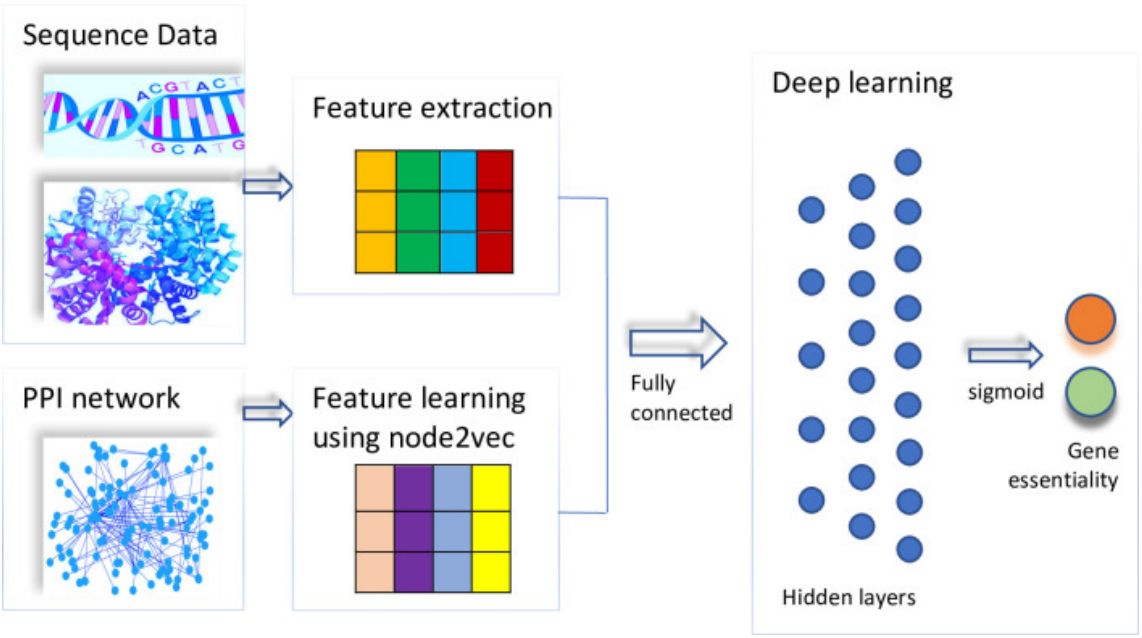


FIGURE 17 – *Architecture du modèle DeepHE [40]*

Phase d'extraction des caractéristiques :

(Xue Zhang, Wangxin Xiao, and Weijia Xiao.) [40] ont alimenté leur réseau de neurone en utilisant les caractéristiques extrait des séquences de nucléotides et des séquences de protéines telles que la fréquences des codons, l'utilisation relative maximale des codons synonymes(RSCUmax), l'indice d'adaptation des codons (CAI), la longueur des gènes, la teneur en GC, la fréquence des acides aminés et la longueur des séquences protéiques. La fréquence des codons d'un gène est calculée en faisant glisser une fenêtre de trois nucléotides le long de sa séquence d'ADN. Le RSCU est une mesure simple qui évalue l'inégalité de l'utilisation des codons synonymes dans une séquence codante. Il est calculé en comparant le nombre d'occurrences d'un codon spécifique avec le nombre d'occurrences attendu si les codons synonymes étaient utilisés de manière uniforme. Dans ce travail, les auteurs ont utilisé le RSCU maximal de chaque gène comme caractéristique. Pour un codon synonyme i avec une dégénérescence de n fois pour un acide aminé, le

RSCU est calculé en utilisant le nombre d'occurrences du codon i, tandis que n représente la dégénérescence qui peut être 1, 2, 3, 4 ou 6 selon le code génétique [40]. Il considère le RSCU maximal de chaque gène comme caractéristique.

$$RSCU = \frac{x_i}{\frac{1}{n}\sum_{i=1}^{n} x_i}$$

Le coefficient d'adaptation des codons (CAI) est une mesure qui évalue le favoritisme envers certains codons qui sont plus fréquents dans les gènes fortement exprimés. L'indice d'adaptation des codons pour un gène est défini en excluant la méthionine, le tryptophane et le codon stop, et en comptant le nombre de codons présents dans le gène (L).

$$CAI = (\prod_{i=1}^{n} r_i)^{\frac{1}{L}} \qquad \text{avec} \qquad r_i = \frac{RSCU}{RSCU_{max}}$$

Pahse de classification avec DeepHE :
DeepHE utilise une architecture de réseau neuronal basée sur un perceptron multicouche. Ce réseau comprend une couche d'entrée, trois couches cachées et une couche de sortie. Les couches cachées utilisent toutes la fonction d'activation de l'unité linéaire rectifiée (ReLU). La fonction ReLU, définie comme $f(x) = max(0,x)$, transforme les valeurs négatives en zéro et augmente linéairement les valeurs positives. Pour effectuer une classification discrète, DeepHE utilise la fonction d'activation sigmoïde dans sa couche de sortie. La fonction de perte utilisée est l'entropie croisée binaire. Après chaque couche cachée, une couche d'abandon est ajoutée pour rendre le réseau moins sensible au bruit dans les données d'apprentissage et améliorer sa capacité de généralisation. Cette couche d'abandon assigne aléatoirement des poids nuls à une fraction des neurones du réseau. Les performances moyennes de prédiction de ce modèle sont mesurées par la précision et AUC qui valent respectivement 0,90 et 0,94.

II.4.3.2. Approche utilisant les réseaux de neurones à rétro-propagation (BPNN)

La théorie de l'information dans le contexte de la génétique fait référence à la discipline qui étudie la transmission de l'information notamment la transmission de l'information génétique. Cette méthode se base de la similitude entre l'hérédité et la transmission de l'information. Les mesures issues de la théorie de l'information peuvent être appliquées à l'analyse des séquences génétiques à différentes échelles.

Certains chercheurs tels que Xiao Liu, Yachuan Luo, Ting He, Meixiang Ren, and Yuqiao Xu. [41] ont orientés leurs travaux sur la théorie de l'information afin

de prédire les gènes essentiels des organismes vivants. Dans cette étude, ils ont extrait 114 caractéristiques des séquences d'ADN de 37 procaryotes en utilisant des méthodes de théorie de l'information. Ensuite, ils ont appliqué ces 114 caractéristiques de la théorie de l'information (IT) pour construire un modèle de prédiction basé sur un réseau de neurones à rétro-propagation (BPNN). Deux méthodes de prédiction différentes, y compris la prédiction intra-organisme et la prédiction sans une espèce, ont été utilisées pour évaluer les performances de prédiction du modèle proposé. Une sélection des fonctionnalités a été effectuée par ces derniers pour améliorer les performances de leur de leur modèle. Notons que la sélection des fonctionnalité fait référence à un processus de traitement de données important dans l'apprentissage automatique qui permet de réduire les fonctionnalités redondantes et de conserver les fonctionnalités clés. Cette sélection à été effectuée en utilisant l'opération de sélection et de retrait le moins absolu (LassoCV) pour filtrer les caractéristiques liées à l'essentialité des gènes. Ce classificateur a été ensuite utilisé pour prédire les gènes essentiels de 37 procaryotes. L'architecture de la méthode proposée est définie sur la figure suivante (figure 18) :

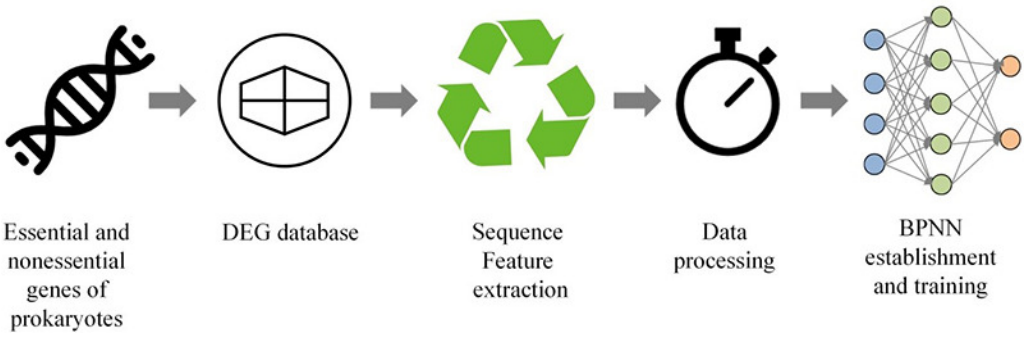


FIGURE 18 – *Architecture du modèle proposé par Xiao Liu, Yachuan L. et Ting He [41]*

Les résultats obtenus par (Xiao Liu, Yachuan Luo, Ting He, Meixiang Ren, and Yuqiao Xu.) [41] dans leurs méthodes sur les 37 procaryotes, sont organisés suivant la prédiction intra-organisme et la prédiction de l'absence d'une espèce. Nous avons respectivement des scores moyens d'AUC de 0,791 et 0,717 sur l'ensemble de toutes les caractéristiques. Afin d'améliorer ces résultats obtenus, les chercheurs ont éliminé la redondance potentielle dans l'ensemble de fonctionnalités, en effectuant une sélection de fonctionnalités pour construire un sous-ensemble de fonctionnalités clés. Dans les deux méthodes de prédiction ci-dessus, les scores AUC moyens de 37 organismes obtenus en utilisant les caractéristiques clés étaient de 0,786 et 0,714, respectivement.

II.5. Conclusion

Dans ce chapitre, nous avons présenté le matériel principal de la génétique, le concept d'essentialité des gènes et l'importance de ces gènes pour un organisme. Ces gènes qui sont des unités de bases de hérédité assurent plusieurs fonctions biologiques afin de maintenir ces organismes en vie. Parmi ces gènes, certains sont très vitaux et leur altération peut causer plusieurs problèmes pouvant conduire à la mort de l'organisme. Cette préoccupation a suscité la curiosité de plusieurs chercheurs et scientifiques dans l'identification de ceux-ci. Pour déterminer le statut d'essentialité des gènes, les chercheurs ont proposé et ne cessent de proposer des solutions basées sur les techniques de machine learning (ML) et de deep learning (DL). Toutefois, Ces méthodes connaissent également plusieurs limites qui empêchent de prédire avec une meilleure précision possible. C'est dans cette optique que nous verrons dans le chapitre suivant une nouvelle approche basée sur les techniques du data mining pour l'extraction des caractéristiques des séquences de gènes et la forêt aléatoire (RF) pour la classification de ces caractéristiques. Notre approche a donc pour objectif de pallier au problème de prédiction des gènes essentiels tout en augmentant le niveau de fiabilité du modèle par rapport aux modèles existants.

III

CHAPITRE

CONTRIBUTION À LA PRÉDICTION DES GÈNES ESSENTIELS

SOMMAIRE

III.1 - Introduction 40
III.2 - Description de l'approche proposée 41
III.3 - Workflow d'exécution de la méthode proposée 41
III.4 - Résultat de simulation et discussion 54
III.5 - Conclusion 64

III.1. Introduction

Les gènes essentiels sont des gènes vitaux à la croissance et à la survie de tout organisme vivants. Leur identification est primordial pour comprendre les mécanismes sous-adjacents aux processus biologiques fondamentaux (la division cellulaire, la synthèse protéique, le métabolisme énergétique), aux processus cellulaires, ainsi que pour identifier de nouvelles cibles thérapeutiques pour le traitement de maladies infectieuses ou génétiques. L'altération d'un gène essentiel peut conduire à des répercussions dangereuses, telles que des défauts de développement, des maladies génétiques ou même la mort de l'organisme. Depuis plusieurs décennies, ces gènes essentiels étaient identifiés en utilisant des méthodes expérimentales. Ainsi, avec l'avènement de l'IA, les approches basées sur l'apprentissage automatique ont été proposées pour compléter les méthodes expérimentales afin de minimiser les ressources nécessaires aux tests d'essentialité de gènes. Des études antérieures ont révélé l'importance de découvrir des caractéristiques pertinentes qui classent de manière significative les gènes essentiels et de permettre une bonne généralisation des modèles de prédiction à travers les organismes. Néanmoins, ces méthodes

informatiques proposées jusqu'à présent laissent quelques inconvénients pour certaines et quelques manquements pour d'autres. Le sujet de prédiction des gènes essentiels étant toujours un sujet d'actualité, il est donc nécessaire de s'orienter afin d'apporter une contribution à la résolution de cet épineux problème. L'objectif principal dans ce chapitre est de vous proposer une nouvelle approche de prédiction des gènes essentiels en utilisant la forêt aléatoire (RF).

III.2. Description de l'approche proposée

Afin de prédire avec précision les gènes essentiels des organismes (notamment les organismes SRB), nous avons proposé une nouvelle approche basée sur le Random Forest pour la classification des gènes. L'idée d'utilisation du random forest est de par sa capacité de ne pas faire du sur-apprentissage et surtout de l'exactitude de ses résultats. Cette approche est décrite par la figure suivante (figure 19) :

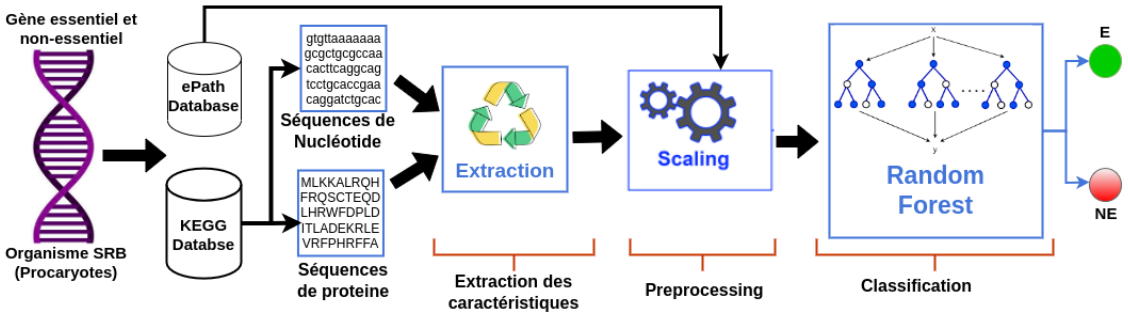


FIGURE 19 – *Architecture de l'approche proposée*

Pour faciliter la compréhension de cette architecture, nous avons proposé un workflow qui décrit de manière exhaustive toutes les étapes qui meuble celle-ci.

III.3. Workflow d'exécution de la méthode proposée

Pour mener à bien notre travail, nous avons subdivisé le processus entre plusieurs étapes. Chacune de ces étapes joue un rôle précis au sein du processus que nous utilisons pour construire la nouvelle approche de prédiction du statut d'essentialité des gènes. La figure 20 vous présente l'ensemble des étapes impliquées dans le processus d'exécution.

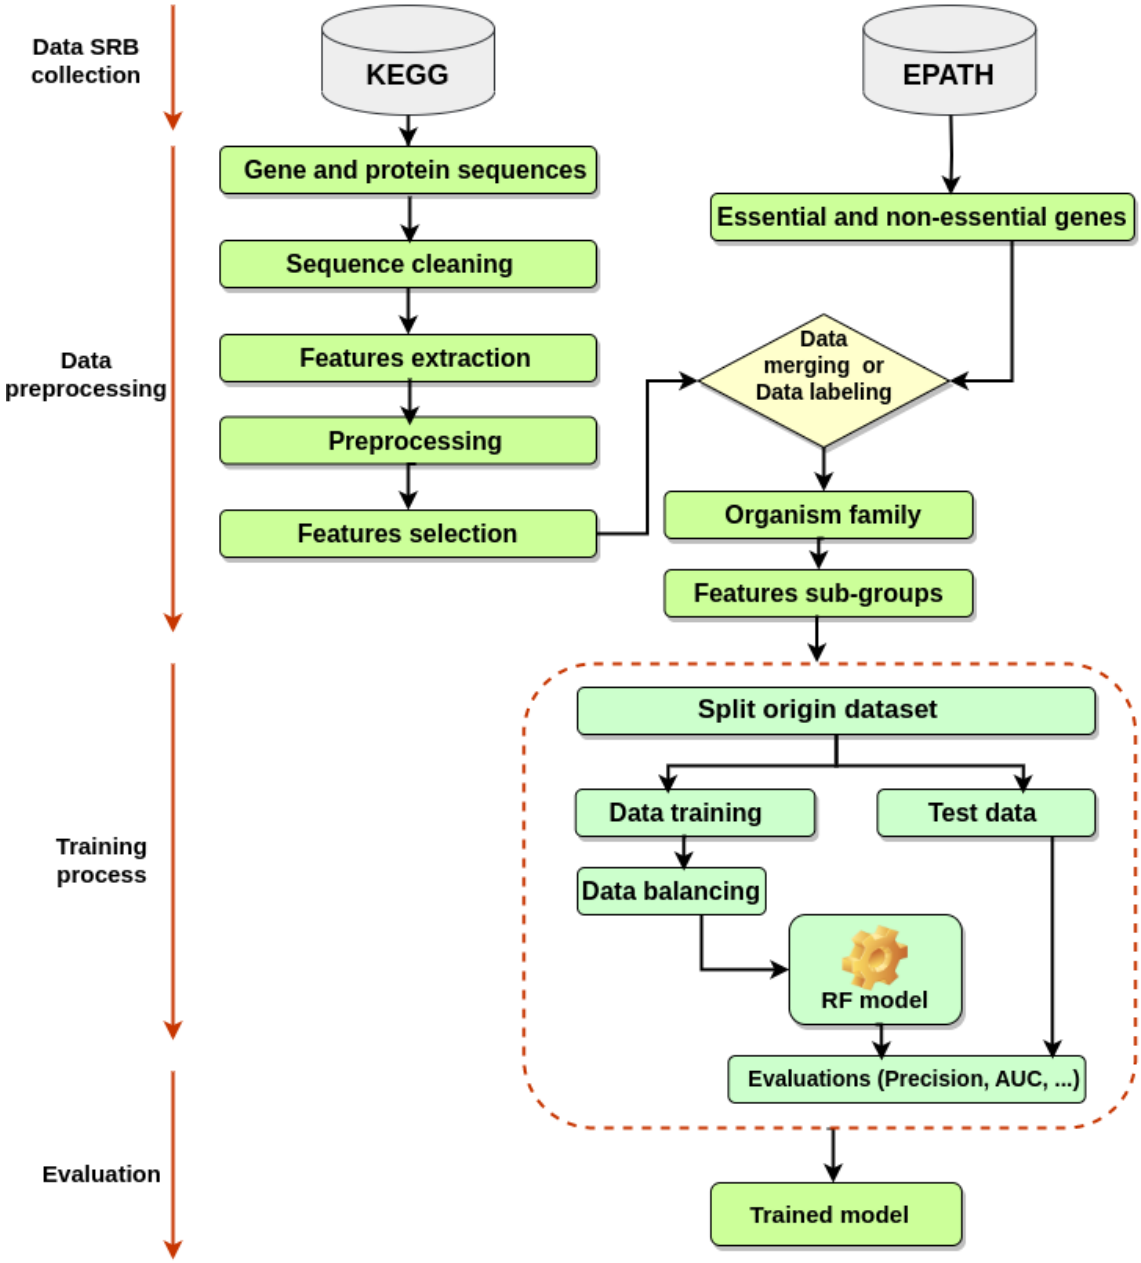


FIGURE 20 – *Workflow d'exécution de l'approche proposée*

III.3.1. Collecte des données sur les organismes SRB (Data SRB collection)

Cette phase est consacrée à la collecte des données des séquences de protéines et de nucléotide des différents organismes SRB (Sulfate-reducing Bacteria) considérés dans ce travail. Notons que Les bactéries sulfato-réductrices (SRB) sont des micro-organismes anaérobies qui utilisent le sulfate comme accepteur terminal d'électrons, par exemple dans la dégradation de composés organiques. Dans ce travail, nous avons collecté au total les données génétiques de 50 bactéries SRB

dans le base de données **KEGG** [12]. **KEGG** est une base de données permettant de comprendre les fonctions de haut niveau et les utilités du système biologique, comme la cellule, l'organisme et l'écosystème, à partir des informations de niveau moléculaire, en particulier les ensembles de données moléculaires à grande échelle générées par le séquençage du génome et d'autres technologies expérimentales à haut débit[12]. Pour chaque organismes, nous enregistrons leur séquence de nucléotides et d'acides aminés sous forme de fichier fasta. Ces données qui sont collectées contiennent l'ensemble des séquences de nucléotides et les séquences de protéines qui ne sont pas annotées. Parmi ces séquences , certaines ont déjà un statut d'essentialité connu. Nous avons récupéré les informations des séquences annotées dans la base de données **ePath** [13]. **ePath** est une base de données qui contient des gènes essentiels et des gènes non essentiels identifiés par des méthodes expérimentales chez les procaryotes. Un gène est considéré comme essentiel dans cette base de données si la condition suivante est vraie : $(E_Score >= 0.6 ou P_Score >= 0.03)$, où E_Score et P_Score représentent respectivement les valeurs de score expérimentales et les valeurs de score prédites.

III.3.2. Data preprocessing

Cette phase est organisée en plusieurs étapes :

— L'étape du **sequence cleaning :**

Cette étape consiste à nettoyer les séquences que nous avons récupérées dans la base de données KEGG. En effet, parmi les séquences récupérées, certaines sont mal formatées et d'autres ne contiennent pas de codon synonyme. Nous supprimons également les informations inutiles pour avoir des séquences de protéines et des séquences de gènes bien structurées. Nous conservons uniquement l'identifiant de la séquence et le contenu de la séquence pour générer les caractéristiques. La figure 21 montre les séquences de gènes et de protéines nettoyées. Pour effectuer ce travail, nous utilisons le package **Biopython**. Biopython est une bibliothèque populaire en bio-informatique qui fournit des outils et des modules pour traiter les données biologiques. Ce package permet de travailler avec des séquences biologiques telles que l'ADN, l'ARN et les protéines. Il offre des fonctionnalités pour la lecture, l'écriture et la manipulation des séquences.



(a) *Fichier fasta construit des nucéotides.* **(b)** *Fichier fasta construit des protéines.*

FIGURE 21 – *Fichiers fasta construit des séquences des nucléotides et des séquences de protéines.*

— Étape **d'extraction des caractéristiques :**
Le processus de génération des fonctionnalités s'est déroulé en trois étapes. La première étape survient juste après le nettoyage des séquences de nucléotides et des protéines. Cette étape consistait à créer les caractéristiques qui simplifient l'analyse des correspondances entre l'utilisation des codons et des acides aminés. Pour créer cet ensemble de caractéristiques, nous avons utilisé la bibliothèque **CodonW** [43] qui est chargée de fournir les indices d'utilisation standard des codons. CodonW est une librairie conçue pour simplifier l'analyse multivariée (analyse de correspondance) de l'utilisation des codons et des acides aminés. CodonW prend en entrée le fichier fasta des nucléotides précédemment construit et fournit deux fichiers en sortie. Le premier fichier (.out) contient les indices d'utilisation des codons calculés pour les séquences d'entrée, et le second fichier (.blk) contient le taux d'utilisation des codons pour chaque gène. CondonW nous a permis également de détecter les séquences qui contiennent les condons d'arrêts internes. Ces séquences ont été tout simplement exclues car elles souffrent d'un mauvais formatage et peuvent biaiser les résultats si elles ne sont pas supprimées.
Dans la deuxième étape, nous avons effectué l'extraction des caractéristiques proprement dites. Pour ce fait, nous avons fait recours aux bibliothèques **protR** qui est une librairie du langage de programmation R [45] et la libraire **iFeature** qui est également basé sur R [46] pour calculer les descripteurs (caractéristiques) de différentes séquences protéiques. À partir des séquences protéiques obtenues à partir de la base de données KEGG, nous avons généré 18477 caractéristiques, regroupées en 27 sous-groupes de

descripteurs (AAC, AAIndex, AC, ACC, APAAC, ASDC, CC, CKSAAGP, CKSAAP, CTDC, CTDD, CTDT, Ctriad, DC, DDE, DistancePair, EGAAC, GAAC, GDPC, Geary, GTPC, KSCtriad, Moran, Moreau, PAAC, QSO, SOCN). Chacun de ces descripteurs est calculé sous la base des formules mathématiques. Nous avons par exemple pour le sous-groupe AAC la formule suivante :

$$f(t) = \frac{N(t)}{N}$$

où $t \in \{A,C,D,E,F,G,H,I,K,L,M,N,P,Q,R,S,T,V,W,Y\}$ et $N(t)$ est le nombre d'occurrence de l'acide aminé de type t et N la longueur de la séquence.

La troisième étape est également consacrée au calcule les descripteurs de séquences géniques à l'aide d'une autre librairie du langage de programmation R nommée **rDNAse** [47]. **rDNAse** est un package capable de générer différents vecteurs de caractéristiques pour les séquences d'ADN. Il calcule trois caractéristiques de composition d'acide nucléique décrivant les informations locales de séquence à l'aide de kmers (séquence d'ADN) ; calcule également six caractéristiques d'autocorrélation décrivant le niveau de corrélation entre deux oligonucléotides le long d'un Séquence d'ADN en fonction de leurs propriétés physico-chimiques spécifiques ; calcule aussi six caractéristiques de pseudonucléotides compositionnelles, qui peuvent être utilisées pour représenter une séquence d'ADN à l'aide d'un modèle ou d'un vecteur discret, tout en conservant une quantité considérable d'informations sur l'ordre de la séquence, en particulier des informations globales ou à longue portée [47]. Nous avons également utilisé la librairie **iFeature** de R pour extrait d'autre caractéristiques [46]. Ces deux packages nous ont permis de générer un total de 10358 caractéristiques réparties en 28 sous-groupes de descripteurs (ANF, CKSNAP, DAC, DACC, DCC, DPCP, EGAAC, EIIP, ENAC, Kmer 2, Kmer 3, LPDF, MMI, NAC, PCPseDNC, PCPseTNC, PseDNC, PseEIIP, PseKNC 3, PseKNC 5, PSTNPds, RCKmer, SCPseDNC, SCPseTNC, TAC, TACC, TCC, TPCP). Ainsi, pour chacun des 50 organismes SRB, nous avons obtenu un total de 28835 caractéristiques.

— Etape du **Preprocessing :**

Cette phase a été consacrée au traitement des données en effectuant les opérations de transformation ou encodage des données afin qu'elles puissent être facilement analysées par les modèles. Ces opérations de transformations nous permettent de traiter les valeurs en double ou manquantes dans nos jeux de données. Ces valeurs aberrantes et les points de données inco-

hérents ont souvent tendance à perturber l'apprentissage global du modèle, conduisant à de fausses prédictions.

— Étape du **feature selection :** A ce niveau, nous employons l'approche de Pertinence maximale - Redondance minimale (MRMR), en anglais). MRMR fonctionne de manière itérative. À chaque itération, elle identifie la meilleure caractéristique selon une règle spécifique et l'ajoute à l'ensemble des caractéristiques sélectionnées. Une fois qu'une caractéristique est incluse dans l'ensemble, elle ne peut plus en être retirée. Le terme MRMR est utilisé car à chaque itération, notre objectif est de sélectionner la caractéristique qui présente la plus grande pertinence par rapport à la variable cible, tout en minimisant la redondance avec les caractéristiques déjà sélectionnées lors des itérations précédentes.

— Étape du **data merging :**
Elle consiste à l'étiquetage des données extraites à l'étape précédente. L'étiquetage des données, est le processus d'étiquetage de différents points de données avec des informations afin que les algorithmes d'apprentissage automatique puissent mieux comprendre leur signification. Les données pour faire cette tâche sont issues de la base de données ePath [13].

— Étape du **regroupement des organismes en famille :**
Pendant cette phase, nous avons regroupé tous les 50 organismes SRB en plusieurs familles suivant leur taxonomie décrite dans la base de données KEGG [12]. Ce regroupement est d'une importance capitale dans notre approche car il nous permet de regrouper les organismes en famille afin de sélectionner les organismes représentant de chaque famille. Ces organismes sélectionnés sont ensuite utilisés pour entraîner les modèles en fonction des différents sous-groupes de caractéristiques pour chaque organisme. En utilisant la taxonomie définie dans KEGG, les groupes des organismes utilisés dans ce travail sont définis dans le tableau suivant :

Nom de la famille	Abréviation de l'organisme	Nom de l'organisme
Archaeoglobus	afu	Archaeoglobus fulgidus DSM 4304
	apo	Archaeoglobus profundus
	ave	Archaeoglobus veneficus
	ast	Archaeoglobus sulfaticallidus
	afg	Archaeoglobus fulgidus DSM 8774
Bacillus	bca	Bacillus cereus ATCC 10987
	bce	Bacillus cereus ATCC 14579

	bcg	Bacillus cereus G9842
	bcu	Bacillus cereus AH820
	bcz	Bacillus cereus E33L
Clostridium	cac	Clostridium acetobutylicum ATCC 824
	cah	Clostridium autoethanogenum
	cbi	Clostridium botulinum Ba4
	ccb	Clostridium cellulovorans
	cck	Clostridium carboxidivorans
	cpr	Clostridium perfringens SM101
	cso	Clostridium cf. saccharolyticum K10
	csq	Clostridium scatologenes
	ctc	Clostridium tetani E88
	cad	Clostridium acidurici
	csr	Clostridium saccharoperbutylacetonicum
	csb	Clostridium saccharobutylicum
	cbe	Bacillus cereus ATCC 14579
	cbh	Clostridium botulinum A Hall
	csd	Clostridium stercorarium subsp. stercorarium DSM 8532
	ckr	Clostridium kluyveri NBRC 12016
Desulfitobacterium	ddl	Desulfitobacterium dichloroeliminans
Desulfobacca	dao	Desulfobacca acetoxidans
Desulfobulbus	dpr	Desulfobulbus propionicus
Desulfococcus	dml	Desulfococcus multivorans
Desulfohalobium	drt	Desulfohalobium retbaense
Desulfosporosinus	dmi	Desulfosporosinus meridiei
	dor	Desulfosporosinus orientis
Desulfotalea	dps	Desulfotalea psychrophila
Desulfotomaculum	dfg	Desulfotomaculum ferrireducens
	dca	Desulfotomaculum nigrificans
Desulfovibrio	dde	Desulfovibrio alaskensis
	dhy	Desulfovibrio hydrothermalis
	dsa	Desulfovibrio salexigens
	dvg	Desulfovibrio vulgaris RCH1
	dvu	Desulfovibrio vulgaris Hildenborough
Desulfurococcus	dmu	Desulfurococcus mucosus

Desulfuromonas	des	Desulfuromonas soudanensis
Paenibacillus	pbv	Paenibacillus bovis
	pjd	Paenibacillus sp. JDR-2
	plv	Paenibacillus larvae
	ppm	Paenibacillus polymyxa SC2
	ppq	Paenibacillus polymyxa SQR-21
	pxl	Paenibacillus xylanexedens
Salmonella	sed	Salmonella enterica subsp. enterica serovar Dublin

TABLE I – *Regroupement des 50 organismes utilisés dans ce travail en famille*

III.3.3. Training process

Cette étape est meublée par l'entraînement des modèles suivant nos différents sous-groupes de caractéristiques. Deux opérations principales sont entreprises ici notamment l'opération d'entraînement et l'opération d'évaluation des modèles entraînés suivant un certain nombre de métriques. Pendant cette phase d'entraînement, nous avons utilisé 40 organismes SRB dont chacune de nos familles précédemment constituées a un tiers de ses représentants parmi ces 40 organismes. Pour chaque sous-groupe, nous formons un jeu de données en concaténant les jeux de données dudit sous-groupe contenu dans chacun des 40 organismes considérés. Cette opération de concaténation est importante dans notre approche car elle nous permet d'avoir dans notre jeux de données, une pléthore d'informations sur les organismes considérés. Le dataset ainsi obtenu est utilisé pour entraîner le modèle du sous-groupe correspondant.

Bien que le jeu de données obtenu à l'étape précédente soit bien labélisé, il souffre d'un problème de déséquilibre des classes. Ce dernier est étiqueté en deux classes (essentiel (1) et non essentiel (0)). Le nombre de gènes non essentiels est largement majoritaire par rapport au nombre de gènes essentiels, soit 33358 gènes non essentiels et 5535 gènes essentiels. Ce déséquilibre est dû au ratio (< 0.5) entre le nombre de gènes annotés et le nombre de gènes non annotés dans la base de données ePath. Cela peut entraîner des performances de modèle biaisées, car les modèles d'apprentissage automatique ont tendance à classer avec précision la classe majoritaire tout en classant de manière erronée la classe minoritaire. Le tableau (II) montre le déséquilibre entre les gènes annotés et les gènes non annotés.

Code organismes	Nombre de gènes essentiels	Nombre de gènes non-essentiels
afu	730	1927
apo	573	1338
ast	682	1606
ave	659	1535
bca	1434	4580
bce	1431	4066
cac	1083	2828
cad	911	2049
cah	1112	2988
cbe	1444	3799
cbi	1020	3235
ccb	1195	3306
cck	1319	3878
cpr	796	1885
csb	1230	3322
csd	912	1728
cso	708	2416
csq	1320	4103
ctc	754	1752
dao	840	2183
dca	923	1918
dde	1047	2317
ddl	994	2531
des	1013	2570
dfg	863	2322
dhy	1080	2573
dmi	1273	3387
dml	1009	2991
dmu	444	881
dpr	1027	2381
dps	963	2360
drt	833	1779
dvg	1015	2324
dvu	998	2635

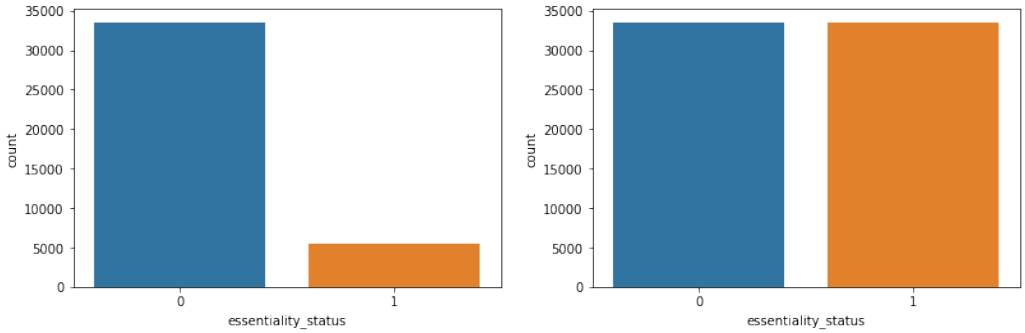
pbv	1424	3349
pjd	1592	4822
plv	1119	3014
ppm	1632	4112
ppq	1593	3581
pxl	1735	4470
sed	1652	3424

TABLE II – *Nombre de gène essentiel et non essentiels des 40 organismes d'entraînement*

Pour résoudre ce problème de déséquilibre de classes afin que les modèles puissent mieux classer les échantillons minoritaires, nous procédons à un rééchantillonnage des données de formation du modèle. Le rééchantillonnage est une étape de prétraitement des données qui vise à résoudre le problème de déséquilibre des classes en rééquilibrant la distribution des classes dans les données d'apprentissage. Parmi les méthodes de sur-échantillonnage, on trouve le suréchantillonnage aléatoire, qui duplique simplement les instances de la classe minoritaire, SMOTE etc. Dans ce travail, la méthode de rééchantillonnage utilisée est SMOTE [44]. SMOTE est une technique de suréchantillonnage utilisée pour équilibrer la distribution de classe d'un ensemble de données en créant des échantillons synthétiques de classe minoritaire. SMOTE crée un nouvel échantillon en sélectionnant au hasard l'un des k voisins les plus proches, puis en ajoutant une petite perturbation au vecteur de caractéristiques entre l'échantillon d'origine et le voisin sélectionné. Cela crée de nouvelles données synthétiques qui sont similaires aux échantillons de classe minoritaire dans l'espace des caractéristiques, mais qui ne sont pas une copie exacte de l'un des échantillons existants. Autrement dit, SMOTE recherche les k échantillons adjacents les plus proches dans chaque échantillon de données x de l'ensemble de données de classe minoritaire et sélectionne au hasard n échantillons dans l'ensemble de données voisin le plus proche enregistré comme $y_1, y_2, \cdots, y_n$. L'opération d'interpolation linéaire aléatoire est effectuée entre les données de la classe minoritaire x et y_i pour construire un nouvel échantillon z_i. L'opération d'interpolation est indiquée dans la formule suivante :

$$z_i = x + \lambda(y_i - x), \qquad i = 1, 2, ..., net\lambda \in [0; 1]$$

La figure suivante montre les propositions des classes avant et après l'opération de rééchantillonage :



(a) *Proposition des classes avant rééchantillonnage* **(b)** *Proposition des classes avant rééchantillonnage*

FIGURE 22 – *propositions des classes avant et après rééchantillonage*

Après cette opération de SMOTE, nous avons une validation croisée pour évaluer l'efficacité de SMOTE, et mesurer la généralisation du modèle. La méthode K-Fold validation utilisée est celle du package skilearn. Cette technique renferme plusieurs stratégies utilisables en fonction de la situation problématique à traverser. Parmi ces stratégies du K-Fold, nous avons Leave One Out, ShuffleSplit, StratifiedKFold, GroupKFold.

— Leave One Out : Encore appelé validation croisée à un seul échantillon exclu, est une méthode simple de validation croisée. À chaque itération, un échantillon est exclu pour former l'ensemble de test, tandis que tous les autres échantillons forment l'ensemble d'apprentissage. Cela signifie que nous avons plusieurs ensembles d'apprentissage et de test pour les différents échantillons. Cette approche de validation croisée est efficace en termes d'utilisation des données, car seule une seule observation est retirée de l'ensemble d'apprentissage.

— ShuffleSplit : est une méthode de cross-validation qui génère de manière itérative un nombre défini par l'utilisateur de fractionnements d'ensembles de données de train/test indépendants. Les échantillons sont d'abord mélangés, puis divisés en une paire d'ensembles de train et de test.

— StratifiedKFold : est une méthode de validation croisée qui permet de construire les fragments du jeu de données dont les classes sont proportionnelles, qui seront utilisées pour le cross-validation. Cette technique consiste à mélanger le jeu de données, puis laisser la machine trier les données en strata (c'est-à-dire en différentes classes) avant de former un nombre k de paquets (K-Fold) qui contiennent tous un peu de données de chaque strata (chaque classe)

— GroupKFold : est une version modifiée de la validation croisée k-fold qui assure que les groupes ne se retrouvent pas à la fois dans les ensembles de

test et d'apprentissage. Par exemple, si les données proviennent de différents sujets avec plusieurs échantillons par sujet et que le modèle peut apprendre des caractéristiques spécifiques à chaque personne, il peut ne pas être en mesure de généraliser à de nouveaux sujets si ces derniers sont présents à la fois dans l'ensemble de tests et d'apprentissage.

Le cross-validation nous a permis de retenir le random forest comme classificateur dans notre travail.

Pour évaluer les performances des modèles, nous utilisons une matrice de confusion. Également connue sous le nom de tableau de contingence, la matrice de confusion permet d'évaluer les performances d'un modèle de classification. La matrice de confusion est en quelque sorte un résumé des résultats de prédiction pour un problème particulier de classification. Elle compare les données réelles pour une variable cible à celles prédites par un modèle. Les prédictions justes et fausses sont révélées et réparties par classe, ce qui permet de les comparer avec des valeurs définies. Dans sa forme la plus simple, il s'agit d'une matrice carrée comme le montre la figure suivante :

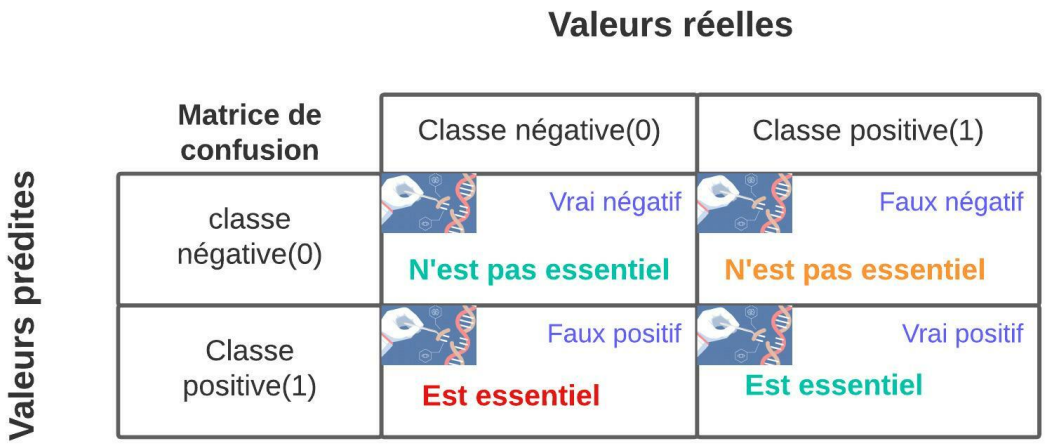


FIGURE 23 – *Matrice de confusion*

Les résultats de cette matrice de confusion sont classés en quatre grandes catégories : les vrais positifs, les vrais négatifs, les faux positifs et les faux négatifs.

- **Vrais négatifs ou TN (true negative) :** représente le nombre de gènes dont le modèle a prédit comme non essentiel et s'est la réalité.
- **Vrais positifs ou TP (true positive) :** représente le nombre de gènes dont le modèle a prédit comme essentiel et s'est la réalité.
- **Faux négatifs ou FN (false negative) :** représente le nombre de gènes dont le modèle a prédit comme non essentiel alors qu'ils sont essentiels.

— **Faux positifs ou FP (false positive) :** représente le nombre de gènes dont le modèle a prédit comme essentiel alors qu'ils ne le sont pas.

A partir de cette matrice de confusion, nous calculons les différentes métriques permettant de de mieux apprécier la qualité de précision du modèle. Ces métriques sont entre autres le taux d'erreur, la précision, du rappel et du F1 score.

Précision

La précision détermine la proportion de prédictions positives qui étaient réellement correctes. Autrement dit, la précision indique le rapport entre les prévisions positives et le nombre total de prévisions positives. Elle est donnée par la formule suivante :

$$Precision = \frac{TP}{TP+FP}$$

Le rappel (Recall)

Le rappel est un paramètre qui permet de mesurer le nombre de prévisions positives correctes sur le nombre total de données positives. Dans le cas de la prédiction des gènes, cela représente le rapport entre le nombre de gènes essentiels reconnus comme tels sur le nombre réel de gènes essentiels. Cette métrique est déterminée par la formule suivante :

$$Recall = \frac{TP}{TP+FN}$$

F1 score

Le F1 Score est une métrique permettant d'évaluer un modèle de classification binaire sur la base des prédictions faites pour la classe positive. Il est calculé à l'aide de Précision et Recall. Il s'agit d'un type de score unique qui représente à la fois la précision et le rappel. Ainsi, le score F1 peut être calculé comme la moyenne harmonique de la précision et du rappel, en attribuant un poids égal à chacun d'eux. La formule pour calculer le F1-score est donnée ci-dessous :

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

À côté de ces métriques énumérées ci-haut, nous utilisons également le AUC (Area under the ROC Curve ou aire sous la courbe ROC en français) pour évaluer les performances de nos modèles. Il mesure la capacité d'un modèle à distinguer correctement entre deux classes (habituellement une classe positive et une classe négative) en termes de probabilités de prédiction. L'aire sous la courbe ROC est calculée en traçant la courbe ROC, qui représente la relation entre le taux de vrais positifs (TP) et le taux de faux positifs (FP) à différents seuils de probabilité, puis en calculant l'aire sous cette courbe.

III.4. Résultat de simulation et discussion

III.4.1. Présentation de l'environnement de travail

Pour implémenter notre approche, nous avons utilisé un ensemble d'outils et de technologies pertinemment choisis. Ainsi, l'approche étant définie et expliquée dans la section précédente, nous avons utilisé Python, Shell, iFeature et Protr pour sa réalisation.

Python : Le langage de programmation de notre approche est le langage Python. Ce choix se justifie par le niveau de popularité de Python dans le monde de l'intelligence artificielle. Il est également le langage de programmation par excellence au sein de la communauté des data scientits. Python est un langage polyvalent qui offre une grande variété de bibliothèques et de frameworks spécialement conçus pour le développement de solutions en intelligence artificielle et en apprentissage automatique.

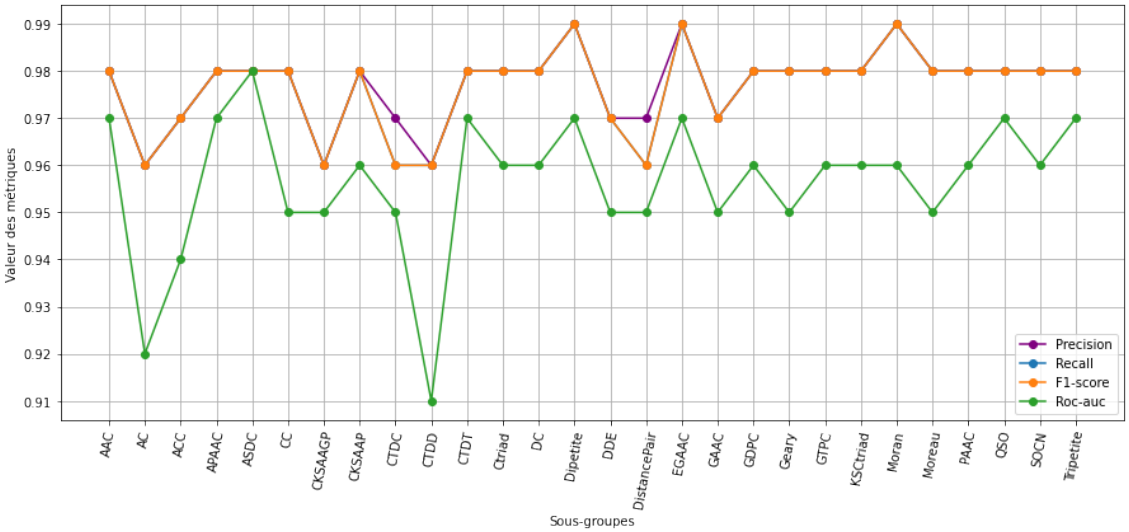
Shell : Nous avons fait recours au langage de programmation shell pour automatiser certains processus dans ce travail. En effet, les scripts en shell ont l'avantage d'être réalisables rapidement et de manière fiable, sans compilation ni installation de commandes supplémentaires.

iFeature[46] et **Protr** [45] : sont des bibliothèques du langage de programmation R. Elles offrent des fonctionnalités permettant de générer divers schémas de représentation numérique de protéines et de peptides à partir d'une séquence d'acides aminés. Ces bibliothèques nous ont permis de de sélectionner les propriétés des acides aminés dans la base de données AAindex et d'utiliser des propriétés auto-définies pour construire des descripteurs personnalisés.

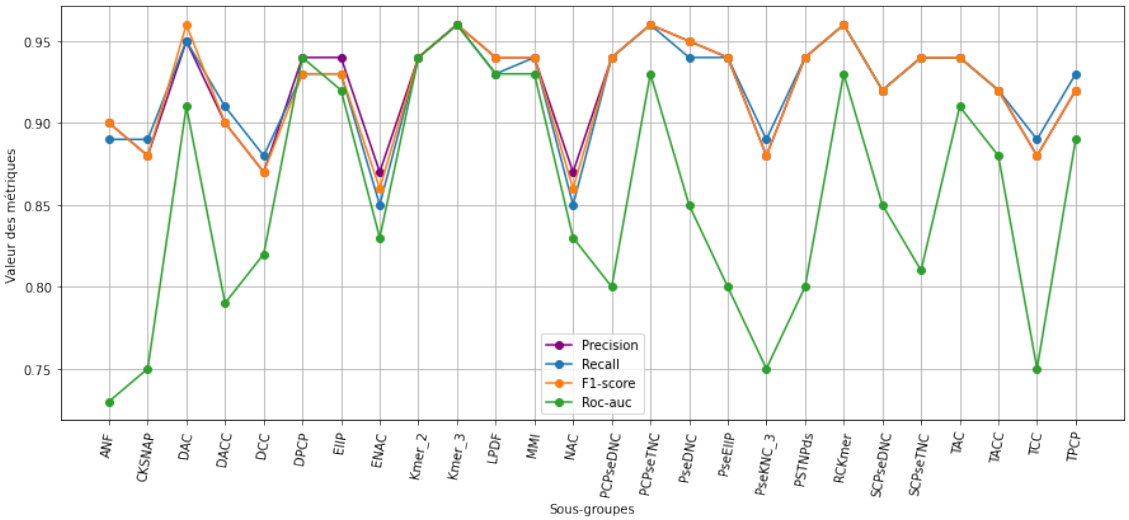
III.4.2. Résultats des simulations

Dans ce travail, nous avons étudié 50 organismes SRB regroupés en familles. Nous avons effectué un regroupement d'échantillons marqués en utilisant les gènes de 40 organismes pour chaque sous-groupe de caractéristique considéré. Ensuite, un modèle a été construit par sous-groupes pour prédire les gènes des 10 organismes SRB restants. L'évaluation de ces 54 modèles qui constituent notre système de prédiction EGPS, se fait sur les métriques de précision, recall, f1 score et auc. Les performances de chaque modèle sur chaque organisme de test sont données par les figures suivantes :

— Pour l'organisme **Archaeoglobus fulgidus DSM 8774 (afg)**, les modèles ont atteints les performances significatives décrites par la figure suivant :



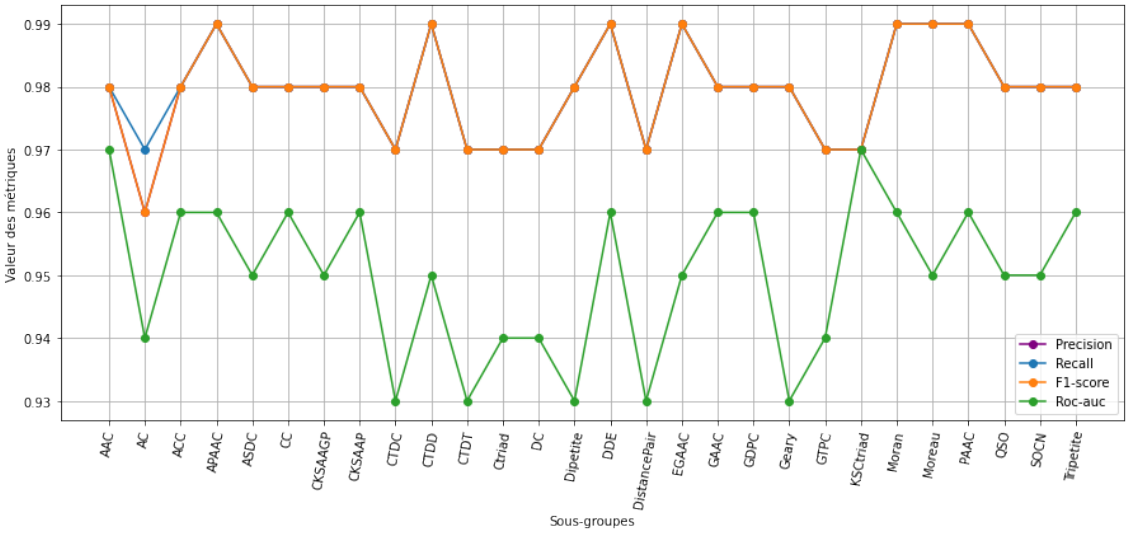
(a) *Performances des modèles sur les sous-groupes de protéine*



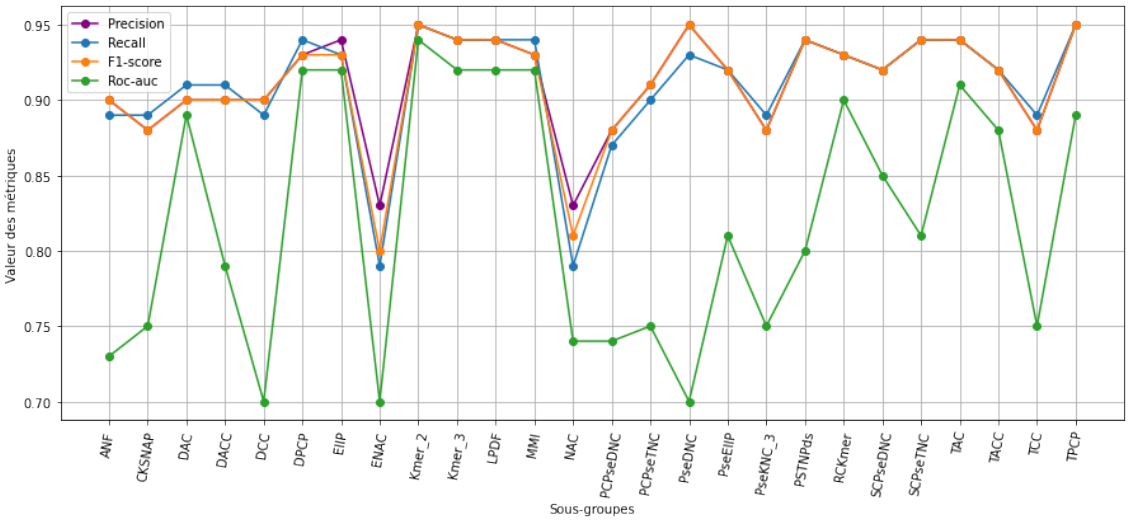
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 24 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme afg*

— Pour l'organisme **Bacillus cereus G9842 (bcg)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



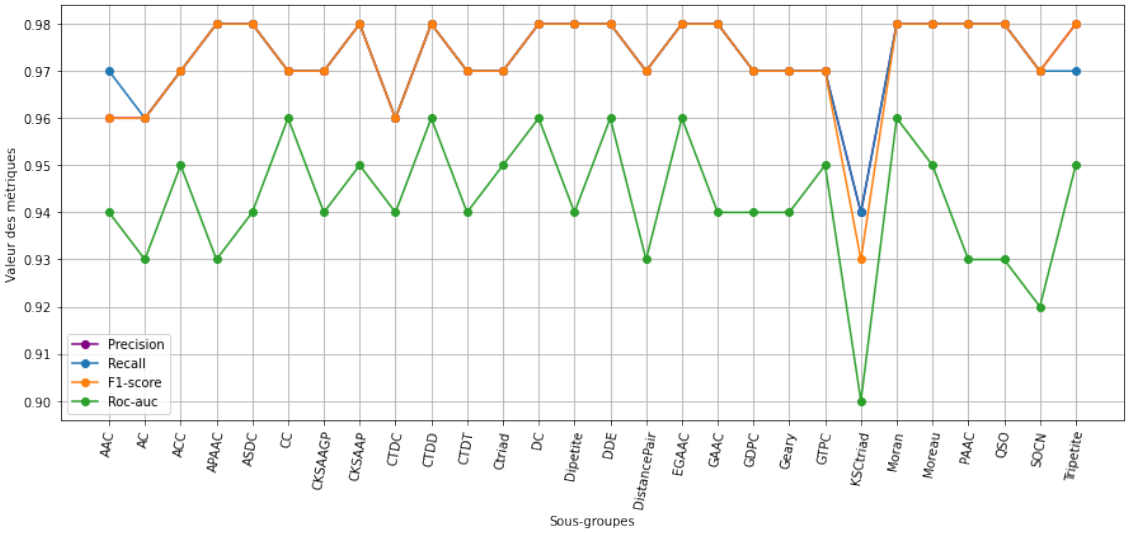
(a) *Performances des modèles sur les sous-groupes de protéine*



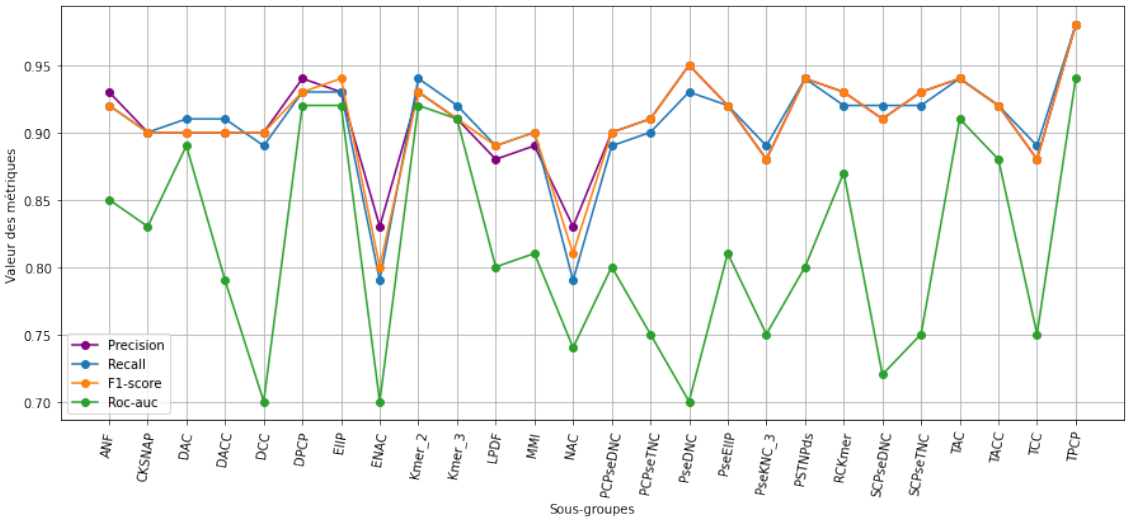
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 25 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme bcg*

— Pour l'organisme **Bacillus cereus AH820 (bcu)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



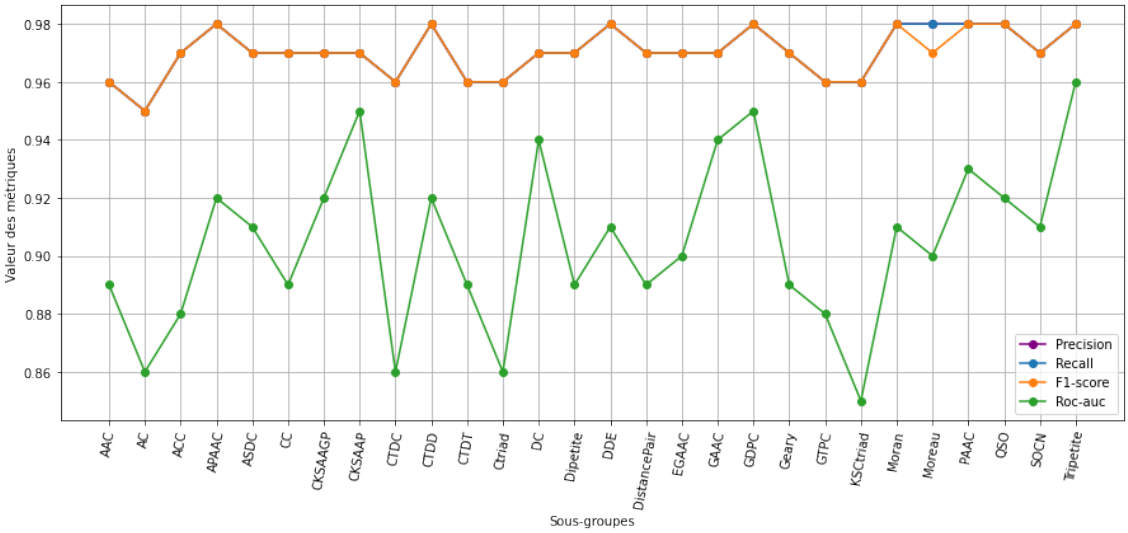
(a) *Performances des modèles sur les sous-groupes de protéine*



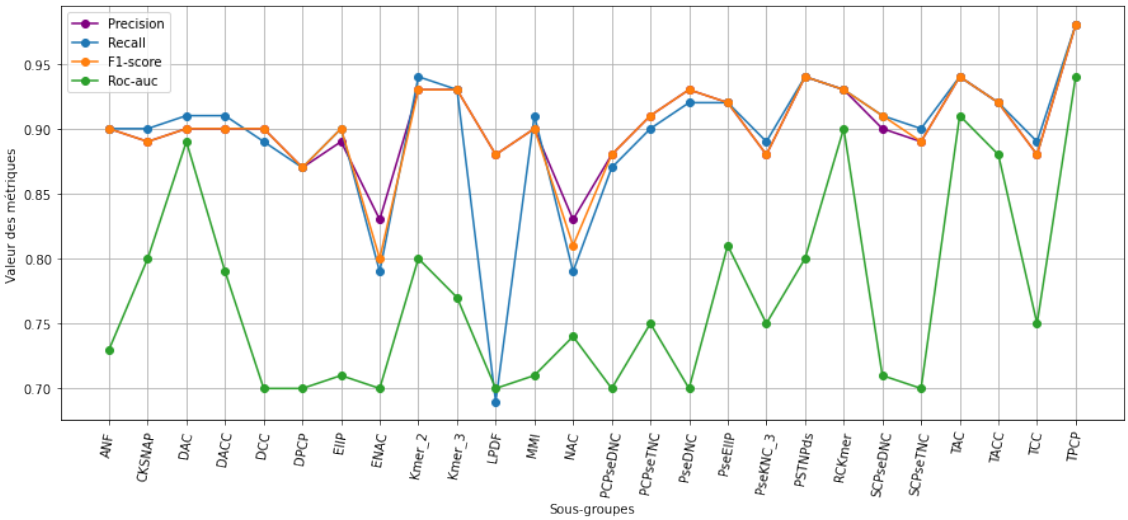
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 26 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme bcu*

— Pour l'organisme **Bacillus cereus E33L (bcz)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



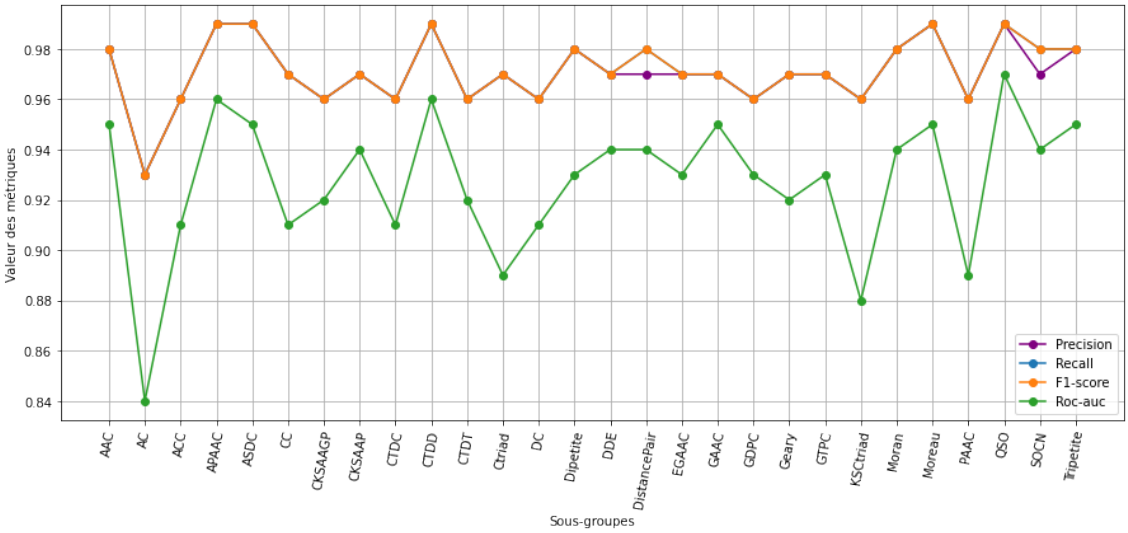
(a) *Performances des modèles sur les sous-groupes de protéine*



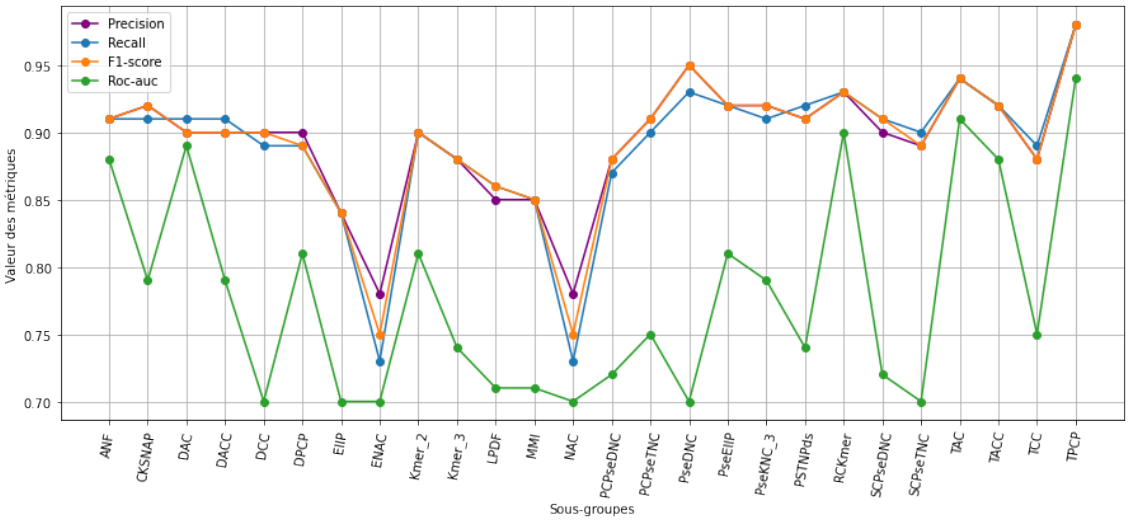
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 27 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme bcz*

— Pour l'organisme **Clostridium botulinum A Hall (cbh)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



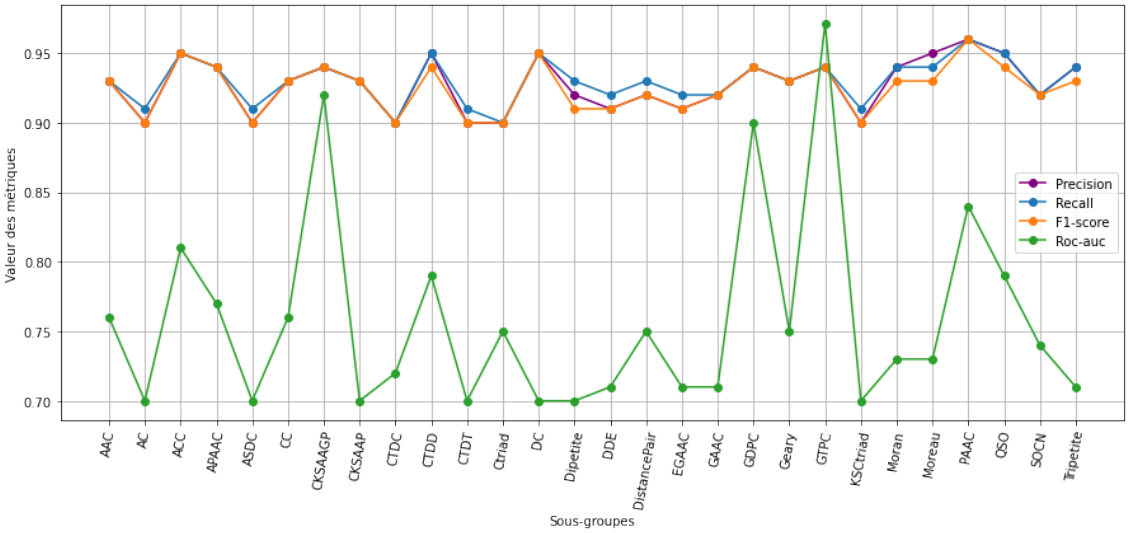
(a) *Performances des modèles sur les sous-groupes de protéine*



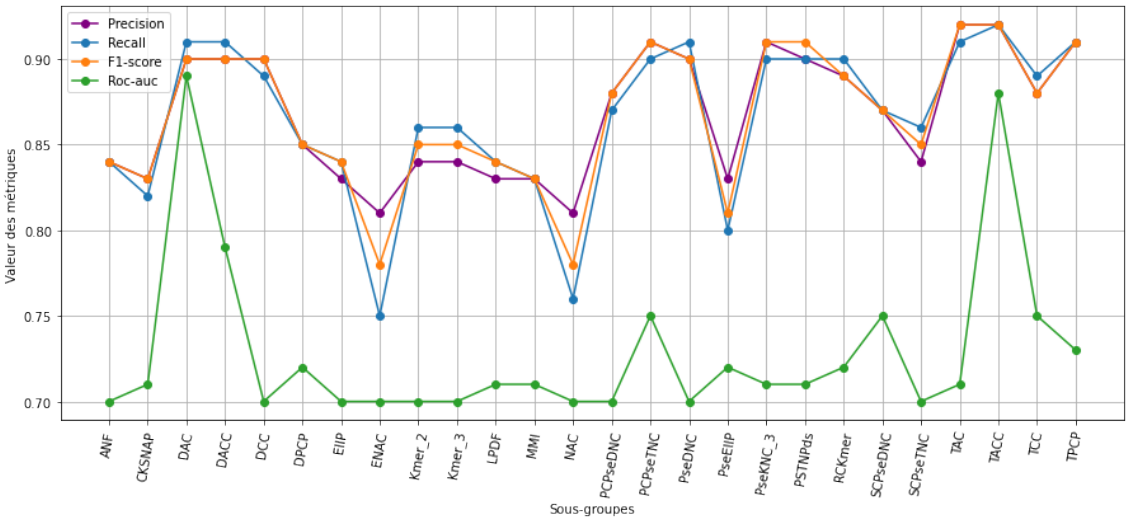
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 28 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme cbh*

— Pour l'organisme **Clostridium saccharoperbutylacetonicum (csr)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



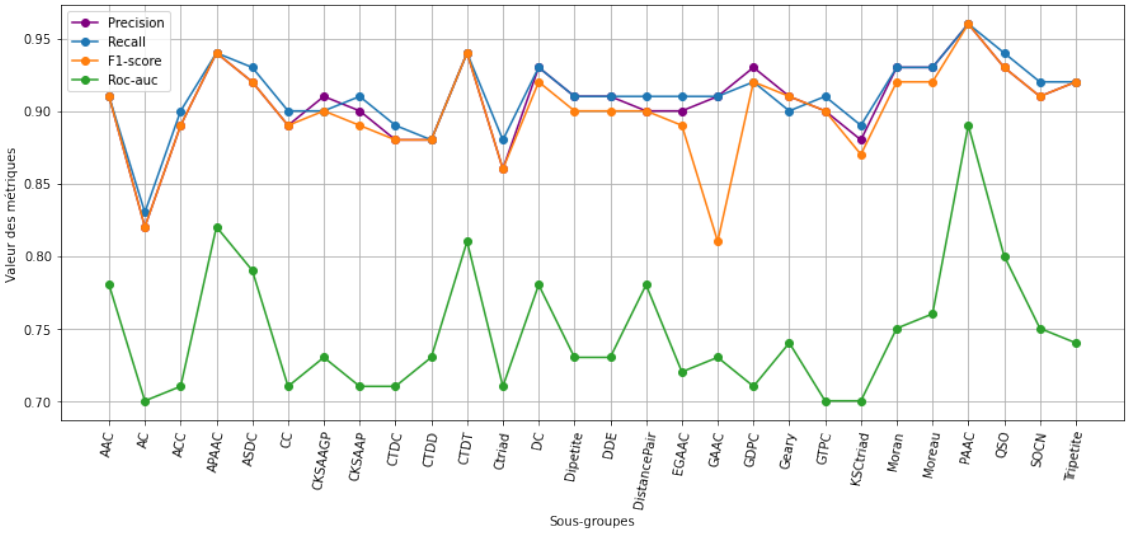
(a) *Performances des modèles sur les sous-groupes de protéine*



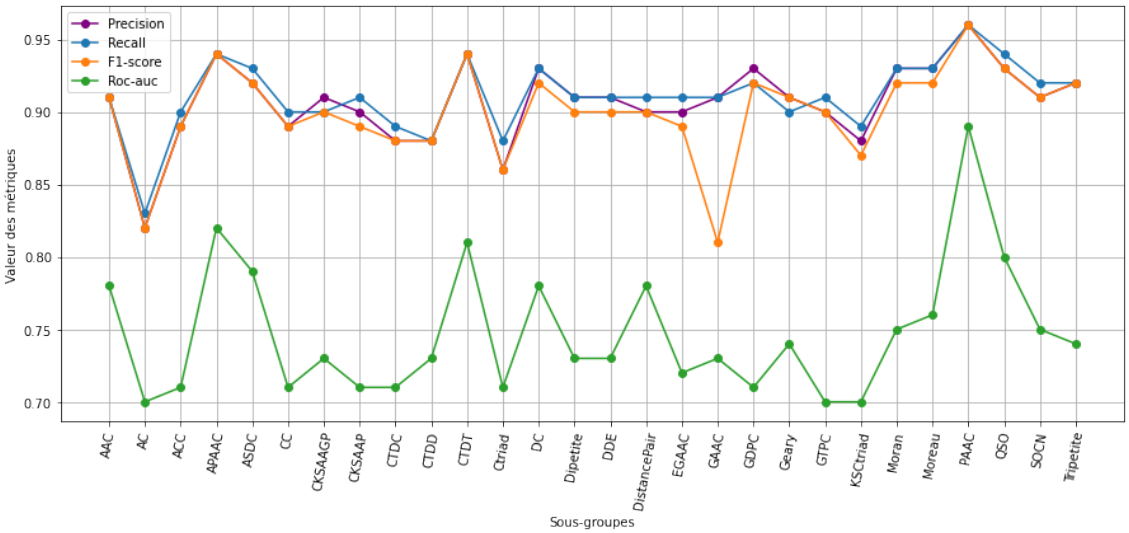
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 29 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme csr*

— Pour l'organisme **Clostridium kluyveri NBRC 12016 (ckr)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



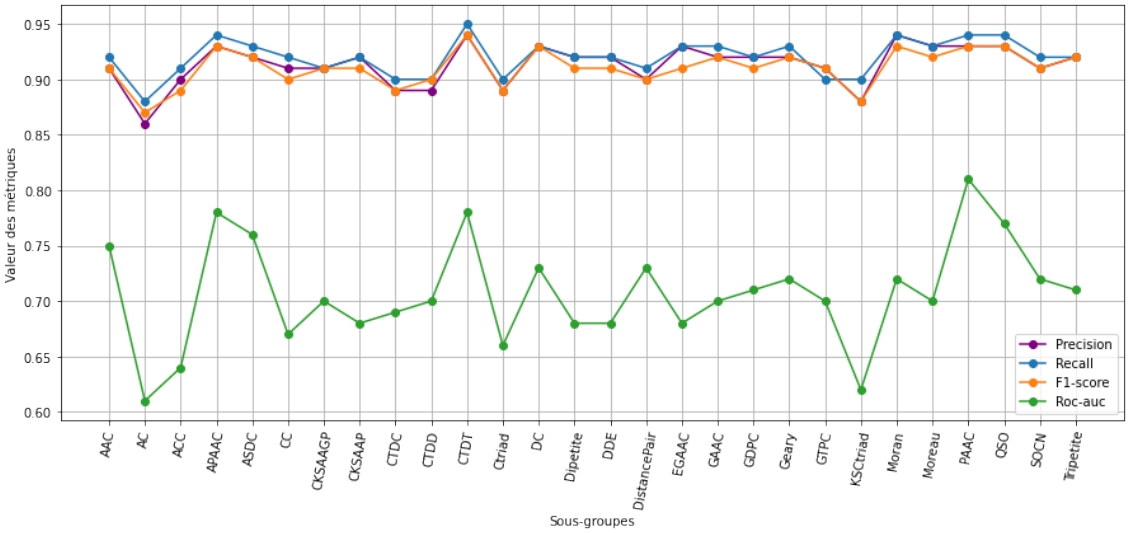
(a) *Performances des modèles sur les sous-groupes de protéine*



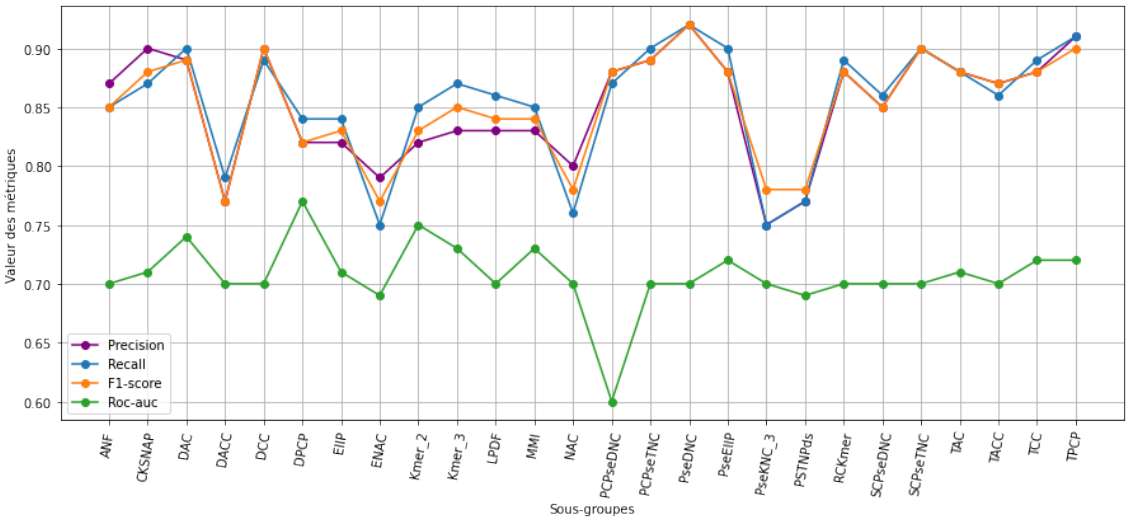
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 30 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme ckr*

— Pour l'organisme **Desulfovibrio salexigens (dsa)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



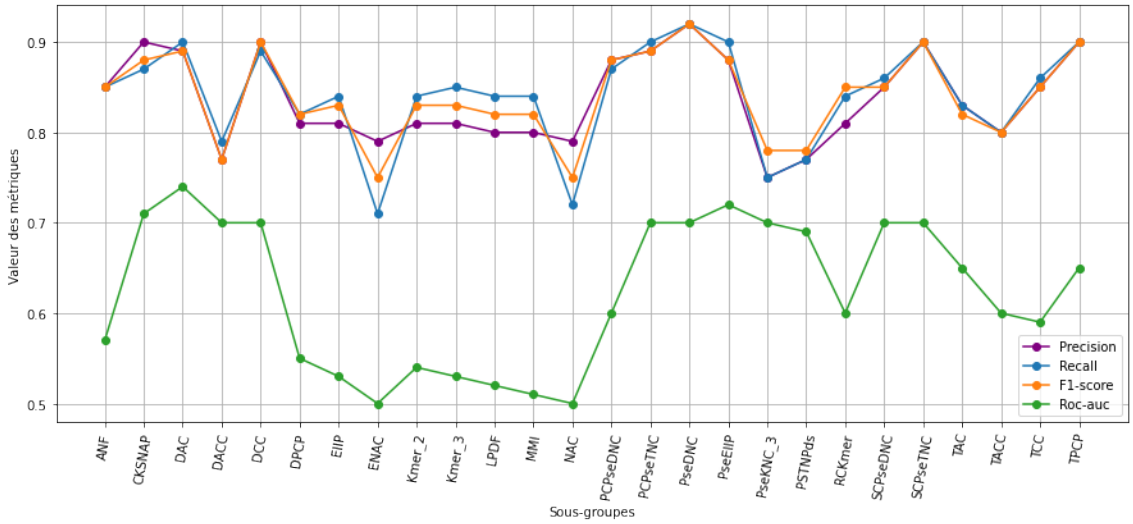
(a) *Performances des modèles sur les sous-groupes de protéine*



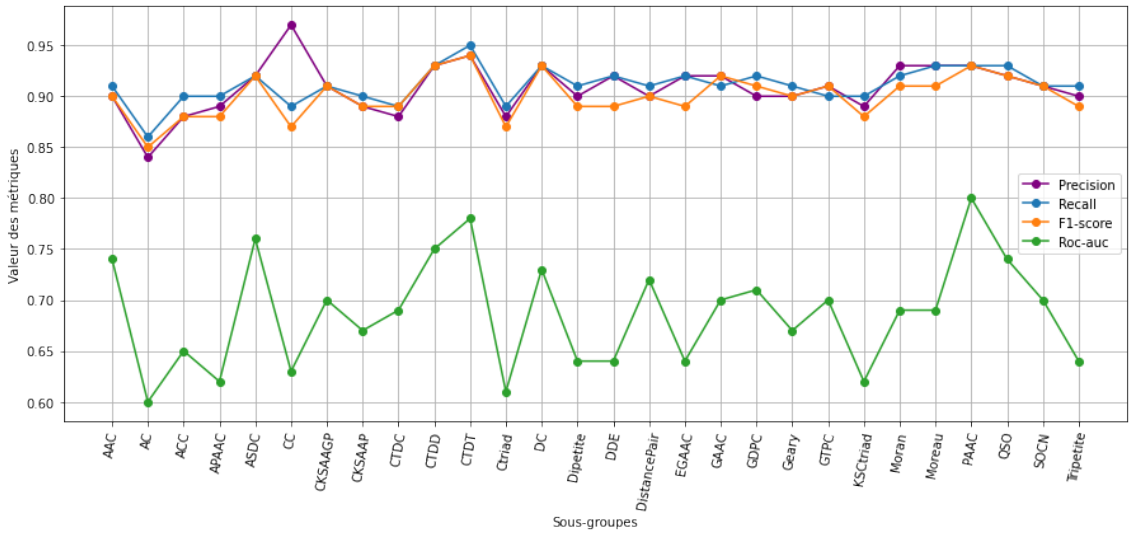
(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 31 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme dsa*

— Pour l'organisme **Desulfosporosinus orientis (dor)**, les modèles ont atteints les performances significatives présenté par la figure suivant :



(a) *Performances des modèles sur les sous-groupes de protéine*



(b) *Performances des modèles sur les sous-groupes de nucléotide*

FIGURE 32 – *Courbes de la précision, du recall, du f1-score et du auc des modèles sur l'organisme dor*

III.4.3. Discussion

Une étude comparative nous a permis de situer notre approche par aux approches évoquées dan la littérature. Dans cette étude, (Xiao L., Ting He, Zhirui G., Meixiang R. et Yachuan L.)[39] ont effectué une prédiction d'exclusion d'une espèce sur 41 organismes en utilisant l'apprentissage semi-supervisé basée sur les graphes. Le score moyen de l'AUC obtenu par ces derniers est $0,663$. Xiao L., Yachuan L., Ting h. Meixiang R. et Yuqiao Xu [41] ont adopté un réseau de neurones à rétro-propagation pour effectué une prédiction d'exclusion d'une espèce sur 37 organismes et ont obtenu un AUC moyen de $0,717$. Au regard de ces résultats, Nous retenons que notre approche fait ses preuves grâces à ses résultats sur

les différents organismes. EGPS avec la précision de ses modèles comprise ente 0.80 et 0.99, du recall comprissent entre 0.8 et 0.99, le f1 score comprissent entre 0.80 et le auc comprissent entre 0.50 et 0.97, surpasses les modèles proposés jusqu'à présent. Ces résultats nous permettent également de ressortir les sous-groupes où les modèles performent le plus. Nous avons à cet effet les sous-groupes AAC, Ctraid, Dipetite, Tripetite, EGAAC, Moran, Moreau, Geary, QSO, SOCN, PAAC, APAAC, AC , DDE, ACC, EGAAC...

III.5. Conclusion

Dans ce chapitre, nous avons proposé une nouvelle approche de prédiction des gènes essentiels chez les organismes SRB (Sulfate reducing Bacteria) en exploitant les techniques du data mining et les algorithmes de machine learning. Cette approche consistait à construire des modèles capable de prédire avec des meilleures performances les gènes des organismes n'ayant jamais connu c'est-à dire être capable de faire la validation inter-organismes. Après avoir décrit notre approche nommé EGPS (essential gene prediction system), nous l'avons tester sur les données de 10 organismes procaryotes. EGPS, présente à issue du test des performances allant de 0.90 à 0.99 pour la précision, 0.90 à 0.99 pour le rappel, 0.80 à 0.97 pour le auc. A l'issue de la comparaison de notre approche avec les méthodes existantes dans la littérature, nous retenons que EGPS présente des performances qui sont largement supérieurs aux résultats des autre travaux dans le domaine.

CONCLUSION GÉNÉRALE

SOMMAIRE

La problématique étudiée et les choix méthodologiques 65
Analyse critique des résultats obtenus 66
Quelques perspectives 66

Pour conclure, nous allons récapituler la problématique abordée dans ce mémoire, puis exposer les principales caractéristiques de la solution proposée, ainsi que ses limites et les critiques pertinentes. Enfin, nous aborderons quelques perspectives envisageables pour des travaux futurs.

La problématique étudiée et les choix méthodologiques

L'évolution du génome des organismes vivants donne et continue de donner d'énormes quantités de gènes pour chacun organisme dû au phénomène de mutation génétique. Parmi ces gènes, certains sont dits essentiels et sont responsables de la survie et à la reproduction des organismes. Ces gènes essentiels sont transmis aux générations suivantes, contribuant ainsi à la diversité génétique et à l'adaptation des espèces aux environnements changeants. L'identification des ces gènes essentiels a été depuis plusieurs décennies assuré par les approches expérimentales (l'inactivation du gène [5], la mutagenèse par transposons [6] et l'interface ARN [7]). Cependant, ces méthodes sont complexes, coûteuses, chronophages et laborieuses au test d'essentialité d'un gène. Dans le but de remédier à cet épineux problème, plusieurs travaux ont été proposés utilisant les algorithmes du Machine Learning (ML) pour prédire les gènes essentiels des espèces. Tous ces travaux ont permis de prouver l'efficacité de ces algorithmes en donnant de bonne performance sur des jeux de données spécifiques des organismes procaryotes et des organismes eucaryotes. Malgré les performances obtenues dans ces travaux, les modèles proposés laissent des marges d'erreurs non négligeables. De plus, ces méthodes ne sont

pas encore déterministes pour la prédiction des gènes inter-organismes. C'est cette dans optique que nous avons proposé dans la suite de ces travaux, une nouvelle approche de prédiction des gènes essentiels basée sur les techniques d'apprentissages automatiques. Cette approche est un système constitué de plusieurs modèles où chaque modèle représente un sous-groupes de caractéristiques que nous avons présenté dans section III.3.2 du chapitre III. SystPredGE rend son jugement en effectuant un vote majoritaire en utilisant les sorties de ses différents modèles. Les modèles de notre système sont basés sur l'algorithme du random Forest (RF).

Analyse critique des résultats obtenus

Sachant que le problème est d'améliorer les performances des modèles de prédiction des gènes essentiels et de faire la validation extra-organisme, nous nous mis sur pied syPredGE pour prédire les gènes essentiels des organismes SRB (Sufate Reducing Bacteria) qui présente des performances bien plus supérieures à celles des méthodes existantes à la fois sur la validation intra-organisme et à la validation inter-organisme. Grâce au principe de vote majoritaire intégré dans notre système, la prédiction du statut d'essensialité d'un gène devient plus fiable. Celà ce justifie par les performances obtenues après le test sur 10 organismes présentés dans la section III.4.2 du chapitre III. SyspredGE malgré ses performances pour prédire le statut d'un gène, n'a pas été testé sur les autres organismes SRB, par conséquent le niveau de performance sur les jeux de données des autres espèces SRB n'est pas vérifié.

Quelques perspectives

À l'issue de ce travail, plusieurs perspectives ont vu le jour dans le même domaine que celui étudié dans ce mémoire. Ces perspectives sont décrites en plusieurs points notamment :

Tester le système proposé avec tous les autres organismes SRB afin de se rassurer sur les performances du système

Ici, il est question de collecter les données sur les organismes SRB restant, puis les passer dans le système et récolter les résultats afin de vérifier si le système proposé nécessite des ajustements.

Adapter notre système pour qu'il puisse prédire les gènes essentiels des autres organismes procaryotes

L'idée ici est d'étendre le nombre d'organismes en prenant en compte les autres organismes procaryotes. Ce qui va nous permettre de créer une nouvelle version de SystPredGE encore plus généralisé.

BIBLIOGRAPHIE

[1] Roman L. Tatusov, Eugene V. Koonin, and David J. Lipman. A genomic perspective on protein families. *Science*, 278(5338) :631–637, 1997.

[2] Michael Y. Galperin, Kira S. Makarova, Yuri I. Wolf, and Eugene V. Koonin. Expanded microbial genome coverage and improved protein family annotation in the COG database. *Nucleic Acids Research*, 43(D1) :D261–D269, 01 2015.

[3] Ozlem Keskin, Nurcan Tuncbag, and Attila Gursoy. Predicting protein–protein interactions from the molecular to the proteome level. *Chemical Reviews*, 116(8) :4884–4909, 2016. PMID : 27074302.

[4] Bertrand Jordan. Genomics and human diversity. *Cahiers de l'Urmis*, 06 2021. disponible à l'adresse : http://journals.openedition.org/urmis/2397.

[5] Lei Chen, Xiuchun Ge, and Ping Xu. *Identifying Essential Streptococcus sanguinis Genes Using Genome-Wide Deletion Mutation*, pages 15–23. Springer New York, New York, NY, 2015.

[6] Shepherd B. Falkow S. Salama, N. R. Global transposon mutagenesis and essential gene analysis of helicobacter pylori. *J. Bacteriol*, 186(23) :7926–7935, 2004.

[7] Lara M Cullen and Greg M Arndt. Genome-wide screening for gene function using rnai in mammalian cells. *Immunology & Cell Biology*, 83(3) :217–223, 2005.

[8] Sircoulomb F Rottapel R Moffat J. Hart T, Brown KR. Measuring error rates in genomic perturbation screens : gold standards for human functional genomics. *Mol Syst BiolEMBO Press*, 733(10), 07 2014.

[9] Xue Zhang, Marcio Luis Acencio, and Ney Lemke. Predicting essential genes and proteins based on machine learning and network topological features : a comprehensive review. *Frontiers in physiology*, 7 :75, 2016.

[10] Yu Chen and Dong Xu. Understanding protein dispensability through machine-learning analysis of high-throughput data. *Bioinformatics (Oxford, England)*, 21(5) :575–581, 06 2005.

[11] Qian Zhou, Saibing Qi, and Cong Ren. Gene essentiality prediction based on chaos game representation and spiking neural networks. *Chaos, Solitons Fractals*, 144 :110649, 2021.

[12] Minoru Kanehisa, Miho Furumichi, Mao Tanabe, Yoko Sato, and Kanae Morishima. KEGG : new perspectives on genomes, pathways, diseases and drugs. *Nucleic Acids Research*, 45(D1) :D353–D361, 11 2016.

[13] Zhu Bin Stone Victoria N. Ge Xiuchun El-Rami Fadi E. Donghai Huangfu Xu Ping Kong, Xiangzhen. epath : an online database towards comprehensive essential gene annotation for prokaryotes. *Scientific Reports*, 9(1), 09 2019.

[14] Anna Choury Benjamin Ejzenberg. Objectif ia : initiez-vous à l'intelligence artificielle. Formation, Janvier 2023. disponible à l'adresse https://openclassrooms.com/fr/courses/6417031-objectif-ia-initiez-vous-a-lintelligence-artificielle/6823506-apprehendez-le-deep-learning-ou-lapprentissage-profond.

[15] intelligence artificielle forte et faible. disponible à l'adresse http://xavier-leca.fr/wp-content/uploads/2018/11/forte-faible-1024x386.jpg.

[16] Seyed Mahdi Miraftabzadeh, Federica Foiadelli, Michela Longo, and Marco Pasetti. A survey of machine learning applications for power system analytics. pages 2–6, 06 2019.

[17] J. N. D. Gupta G. Huang, S. Song and C. Wu. Semi-supervised and unsupervised extreme learning machines. *IEEE Transactions on Cybernetics*, 44(12) :2405–2417, 12 2014.

[18] Problème de régression et de classification. disponible à l'adresse https://user.oc-static.com/upload/2016/09/18/14742103795655_ml.png.

[19] Pitpitt (P.). Apprentissage semi-supervisé — datafranca. Formation. disponible à l'adresse https://datafranca.org/wiki/Apprentissage_semi-supervis%C3%A9.

[20] Patrick Zschech Christian Janiesch and Kai Heinrich. Machine learning and deep learning. *Electronic Markets*, 31(3) :685–695, 09 2021.

[21] Wikipedia. Reinforcement learning. Formation, Juin 2023. disponible à l'adresse https://en.wikipedia.org/wiki/Reinforcement_learning.

[22] Ikram Chraibi Kaadoud. Architecture des réseaux de neurones : Réseaux de neurones artificiels classiques (2/3) !, nov 2018. disponible à l'adresse https://scilogs.fr/intelligence-mecanique/architecture-des-reseaux-de-neurones-reseaux-de-neurones-artificiels-cl

[23] Messaoud DJEDDOU. *Prediction of Failure rate with Artificial Neural Networks in a WasteWater Treatment Plant*$_{FrenchCopy}$. *PhDthesis*, 122014.

[24] Carl Kriger. Prediction of the influent wastewater variables using neural network theory. *Cape Peninsula University of Technology*, page 331, 2007.

[25] Joos Korstanje. *LSTM RNNs*, pages 243–251. Apress, Berkeley, CA, 2021.

[26] Arvindpdmn Anuradhac. Long short-term memory. *Devopedia*, oct 2019.

[27] Ouadou Anes Max Highsmith Duan Ye Tanner-John J. Cheng Jianlin Al-Azzawi, Adil. Deepcryopicker : fully automated deep neural network for single protein particle picking in cryo-em. *BMC Bioinformatics*, 21(1) :509, sep 2020.

[28] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. *Commun. ACM*, 60(6) :84–90, may 2017.

[29] Weili Fang, Peter E.D. Love, Hanbin Luo, and Lieyun Ding. Computer vision for behaviour-based safety in construction : A review and future directions. *Advanced Engineering Informatics*, 43 :100980, 2020.

[30] Jiuxiang Gu, Zhenhua Wang, Jason Kuen, Lianyang Ma, Amir Shahroudy, Bing Shuai, Ting Liu, Xingxing Wang, Gang Wang, Jianfei Cai, and Tsuhan Chen. Recent advances in convolutional neural networks. *Pattern Recognition*, 77 :354–377, 2018.

[31] Ajitesh Kumar. Different types of cnn architectures explained : Examples - data analytics, mai 2023.

[32] What is data mining : Definition, examples, tools, and techniques (for beginners). disponible à l'adresse = https ://bootcamp.pe.gatech.edu/blog/what-is-data-mining/.

[33] Chromosome : définition, structure, simple, double, schémae, Mai 2022. disponible à l'adresse https://img-3.

journaldesfemmes.fr/EviAwDRKlCDi0NeH6PXkC5iQC00=/1080x/smart/fdda1f9132aa4b6b86c4a1c916020341/ccmcms-jdf/34383945.jpg.

[34] Lohani M. Aggarwal R. Sarangi, A. N. Prediction of essential proteins in prokaryotes by incorporating various physico-chemical features into the general form of chou's pseudo amino acid composition. *Protein and peptide letters*, 20(7) :781–795, Jul 2013.

[35] Olufemi Aromolaran, Thomas Beder, Marcus Oswald, Jelili Oyelade, Ezekiel Adebiyi, and Rainer Koenig. Essential gene prediction in drosophila melanogaster using machine learning approaches based on sequence and functional features. *Computational and Structural Biotechnology Journal*, 18 :612–621, 2020.

[36] Tulio L. Campos, Pasi K. Korhonen, Robin B. Gasser, and Neil D. Young. An evaluation of machine learning approaches for the prediction of essential genes in eukaryotes using protein sequence-derived features. *Computational and Structural Biotechnology Journal*, 17 :785–796, 2019.

[37] M.A. Sarah A. Bates, M.S. Deoxyribonucleic acid (dna), 06 2023. disponible à l'adresse https://www.genome.gov/genetics-glossary/Deoxyribonucleic-Acid.

[38] acide désoxyribonucléique (adn). disponible à l'adresse https://www.larousse.fr/encyclopedie/divers/acide_d%C3%A9soxyribonucl%C3%A9ique_ADN/42551.

[39] Xiao Liu, Ting He, Zhirui Guo, Meixiang Ren, and Yachuan Luo. Predicting essential genes of 41 prokaryotes by a semi-supervised method. *Analytical Biochemistry*, 609 :113919, 2020.

[40] Xue Zhang, Wangxin Xiao, and Weijia Xiao. Deephe : Accurately predicting human essential genes based on deep learning. *PLOS Computational Biology*, 16(9) :1–17, 09 2020.

[41] Xiao Liu, Yachuan Luo, Ting He, Meixiang Ren, and Yuqiao Xu. Predicting essential genes of 37 prokaryotes by combining information-theoretic features. *Journal of Microbiological Methods*, 188 :106297, 2021.

[42] Lilli J Freischem, Mauricio Barahona, and Diego A Oyarzún. Prediction of gene essentiality using machine learning and genome-scale metabolic models. *IFAC-PapersOnLine*, 55(23) :13–18, 2022. 9th IFAC Conference on Foundations of Systems Biology in Engineering FOSBE 2022.

[43] J. Peden. Codonw version 1.4. 2. university of nottingham : Nottingham, uk, 2005.

[44] Gustavo E. A. P. A. Batista, Ronaldo C. Prati, and Maria Carolina Monard. A study of the behavior of several methods for balancing machine learning training data. *SIGKDD Explor. Newsl.*, 6(1) :20–29, jun 2004.

[45] Nan Xiao, Dong-Sheng Cao, Min-Feng Zhu, and Qing-Song Xu. protr/ProtrWeb : R package and web server for generating various numerical representation schemes of protein sequences. *Bioinformatics*, 31(11) :1857–1859, 01 2015.

[46] Zhen Chen, Pei Zhao, Fuyi Li, André Leier, Tatiana T Marquez-Lago, Yanan Wang, Geoffrey I Webb, A Ian Smith, Roger J Daly, Kuo-Chen Chou, and Jiangning Song. iFeature : a Python package and web server for features extraction and selection from protein and peptide sequences. *Bioinformatics*, 34(14) :2499–2502, 03 2018.

[47] Dong-Sheng Cao Min-feng Zhu, Jie Dong. rdnase : R package for generating various numerical representation schemes of dna sequences, 07 2016. available at https://cran.r-project.org/web/packages/rDNAse/vignettes/rDNAse.pdf.